

Chapter 3

Memory Management For LLM

上下文学习与提示词工程

短期记忆与会话管理

长期记忆与知识库


LLM Wiki



大语言模型的“幻觉”问题



描述一下阿富汗战争的相关信息



The United States has been accused of a wide ranging war in Afghanistan since 9/11. During the campaign, US forces in Afghanistan were involved in an extensive air campaign. At least 1,600 American servicemen and women were killed, while more than 1,600 civilians were injured. After the US-led invasion of Afghanistan on 12/11/2001, an estimated 10,000 American soldiers were killed in combat.

伤亡与损失

阿富汗保安部队：6,500人	超过5.1万人阵亡 ^[34]
阵亡	
北方联盟：200人阵亡	
联军：超过3,500人阵亡 ^[32] ，英国313人、其他433人	
超过1.5万人负伤	
美国民间承包商：338人阵亡、7,224人负伤 ^[33]	
总共9千人阵亡、2.5万人负伤	


超过2,400人死亡^[21]

大语言模型的“幻觉”问题



找一篇关于无线感知的最新的参考文献

Li D., Wu T., and Sophia V. LLM-based Wireless Human Sensing Survey: Application and Open Issues. ACM Computing Surveys, 2026, 8(20): 123-146



Google 学术搜索

LLM-based Wireless Human Sensing Survey: Application and Open Issues

文章 找到约 1,080 条结果 (用时0.14秒)


时间不限
2026以来
2025以来
2022以来
自定义范围...

按相关性排序
按日期排序

Wireless Human Activity Recognition: A Survey of Recent Advances and a Novel Zero-Shot LLM-Based Inference Framework [PDF] ssrn.com
Z Xing, X Zhang, W Liu, H Xing, W Zhao... - IEEE Transactions ..., 2026 - ieeexplore.ieee.org
... wireless sensing systems are able to infer activities in a device-free and non-intrusive manner. In this section, we categorize existing WiFi-based human sensing ... remains an open issue, ...
☆ 保存 引用 相关文章 所有 2 个版本

ISAC Meets LLMs: Advancing from Sensing to Reasoning with Foundation Models and Flexible Intelligent Metasurfaces [PDF] authorea.com
M Rahaman, A Adhikary, T Debnath, Y Qiao... - Authorea ..., 2026 - authorea.com

1.1 如何让LLM不乱说话呢？



1.2 Prompt Engineering

Let's think step by step

让AI把推理结果一步一步写出来



屋子里有一些鸡和兔子，总共有23个头，67只腿。问：有多少只鸡和多少只兔子？直接告诉我答案



鸡有13只，兔子有10只。

屋子里有一些鸡和兔子，总共有23个头，67只腿。问：有多少只鸡和多少只兔子？一步一步的推理



这是一个经典的鸡兔同笼问题，我们可以通过代数方程来解决。假设鸡的数量是 x 只，兔子的数量是 y 只。根据题意，有两个条件：

1. 总共有23个头：每只鸡和每只兔子都有一个头，因此：

$$x + y = 23$$

2. 总共有67只腿：每只鸡有2只腿，每只兔子有4只腿，因此：

$$2x + 4y = 67$$

步骤 1：解第一个方程

从第一个方程 $x + y = 23$ 中，解出 y ：

$$y = 23 - x$$

步骤 2：代入第二个方程

将 $y = 23 - x$ 代入第二个方程 $2x + 4y = 67$ 中：

$$2x + 4(23 - x) = 67$$

展开并简化：

$$2x + 92 - 4x = 67$$

$$-2x + 92 = 67$$

$$-2x = 67 - 92$$

$$-2x = -25$$

$$x = 12.5$$

但是，鸡和兔子的数量应该是整数，所以这个结果看起来不合适。我们是否需要更改原始方程的解法。



1.2 Prompt Engineering

Provide some background

多交代一些背景



已阅读 20 个网页

今天的天气情况如下：

- 深圳地区：**白天和夜间都是晴朗的天气，气温在11℃到21℃之间，东风。3级，风力适中，紫外线指数为弱，适宜旅游、晨练和晾晒。
- 北京地区：**今天白天北京天气晴朗，最高气温13℃，最低气温2℃。风向为北风，风力3级，紫外线强度强，空气质量为优，指数为40。
- 全国天气情况：**全国大部地区降水稀少，东北及淮河以南地区气温继续回升。较强冷空气将影响长江中下游以北地区，内蒙古东北部、东北地区以及新疆西部和北部有明显降雪。

综上，今天大部分地区天气晴朗，气温有所回升，但部分地区如东北和新疆会有降雪，外出时请注意查看当地具体天气预报。

探索一下

复制

再试一次

分享

黄石的天如何





已阅读 33 个网页

根据最新的天气预报信息，2024年11月30日黄石的天气情况如下：

- 天气状况：晴。
- 气温范围：最低气温4℃，最高气温20℃。
- 风力风向：风力小于3级，无持续风向。

建议您根据这样的天气情况，适当穿着，享受晴朗的天气。同时，由于紫外线指数较强，外出时请做好防晒措施。

探索一下

复制

再试一次

分享

1.2 Prompt Engineering

Clear Output Format 规定准确的输出格式

“比较黄石地区近三天的天气情况”

1. 2024年12月1日（星期日）：

 - 最高温度：22°C
 - 最低温度：8°C
 - 白天天气：晴
 - 夜间天气：多云
 - 风向：东北风
 - 风力：小于3级 ”
2. 2024年12月2日（星期一）：

 - 最高温度：23°C
 - 最低温度：10°C
 - 白天天气：多云
 - 夜间天气：多云
 - 风向：东北风转西南风
 - 风力：小于3级 ”
3. 2024年12月3日（星期二）：

 - 最高温度：18°C
 - 最低温度：9°C
 - 白天天气：晴
 - 夜间天气：小雨
 - 风向：东北风转西南风
 - 风力：小于3级 ”

形式不合适
难做比较

Prompt+“用表格的形式展现”

日期	最高温度(°C)	最低温度(°C)	白天天气	夜间天气	风向
2024年12月1日	22	8	晴	多云	东北风
2024年12月2日	23	10	多云	多云	东北风转西南
2024年12月3日	18	9	晴	小雨	东北风转西南

明确的形式保证信息的准确传达

1.3 In-Context Learning


做情感分析：“这部电影真是太精彩了，我强烈推荐！”

参考案例：

“这家餐厅的服务非常周到，食物也很棒，下次还会再来。”




“我对这次的服务非常失望，等待时间太长了。”



LLM真的知道吗？

“我对我的新工作感到非常满意，同事们都很友好。”



“这部电影的剧情太无聊了，我几乎要睡着了。”



<https://arxiv.org/pdf/2005.14165>

1.3 In-Context Learning

Prompt:

做情感分析，根据示例判断语句的情感。

示例1，输入：这家餐厅的服务非常周到，食物也很棒，下次还会再来。输出：负面情感。

示例2，输入：我对这次的服务非常失望，等待时间太长了。输出：正面情感。

请学习示例内容再判断下句话的情感：我对这个产品的质量感到非常不满，它完全不符合我的期望。


In-context Learning
上下文学习

让LLM更好的遵循提示词

Prompt Engineering
提示词工程

“我对我的新工作感到非常满意，同事们都很友好。”

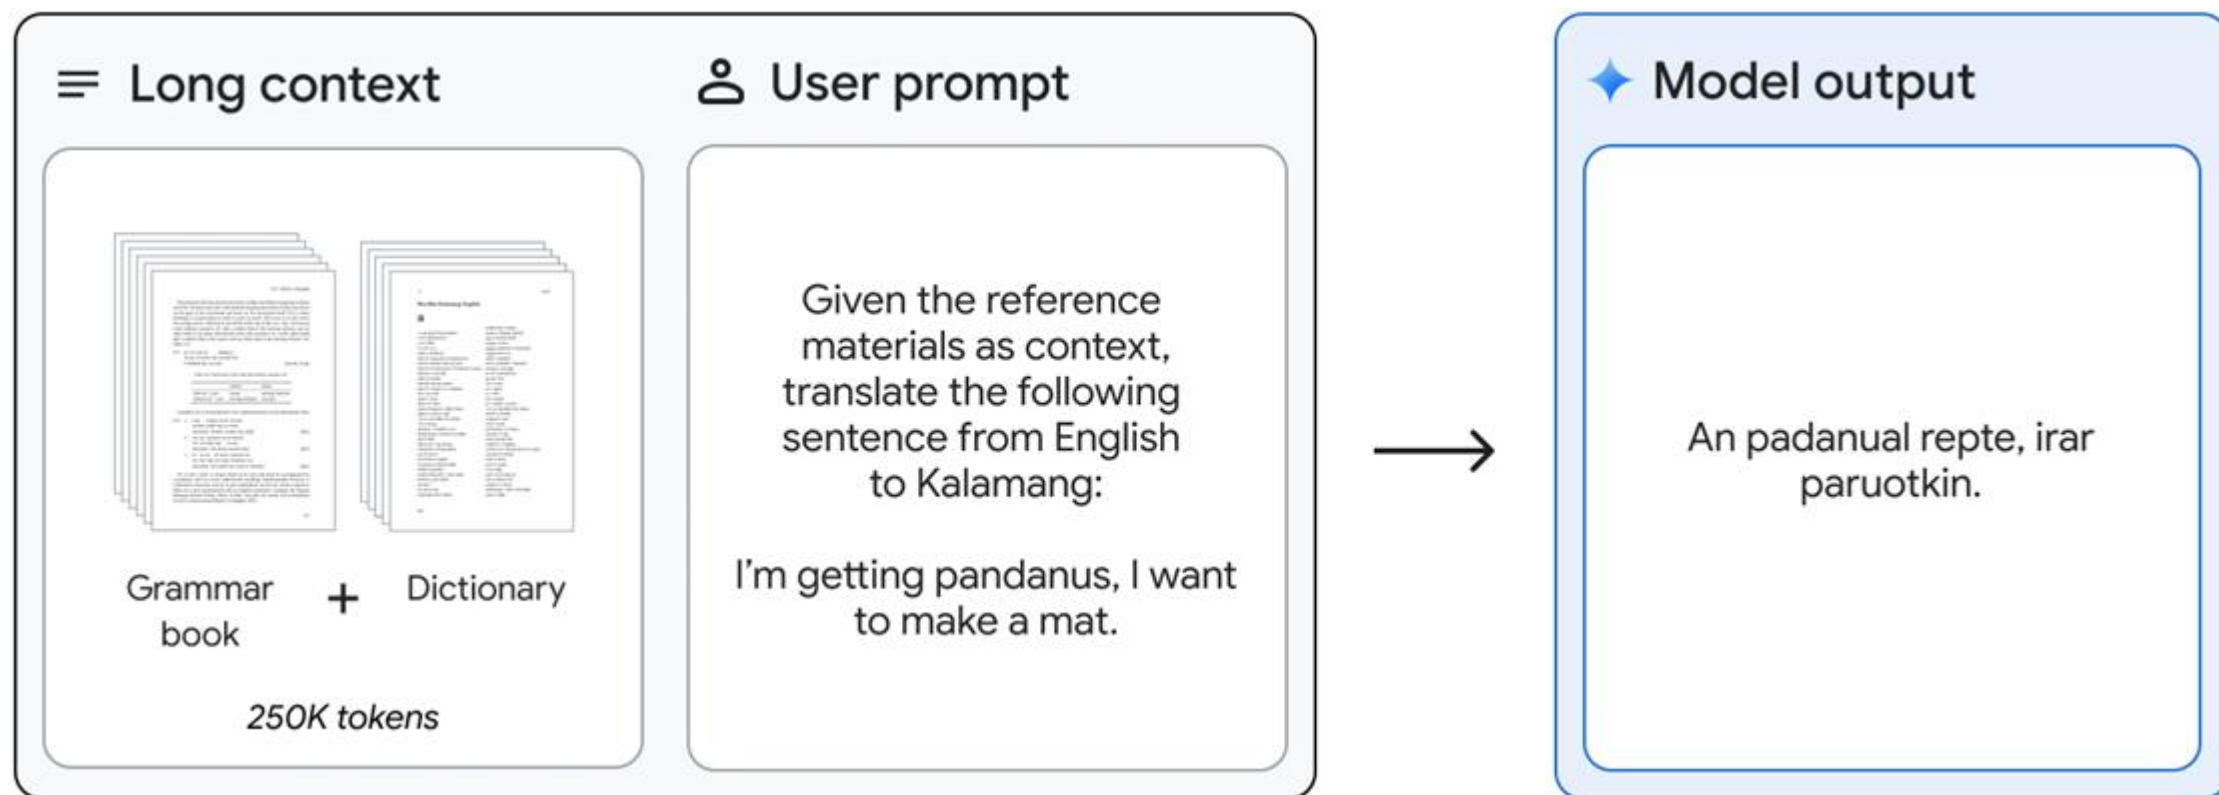
“这部电影的剧情太无聊了，我几乎要睡着了。”



<https://arxiv.org/pdf/2005.14165>

1.3 In-Context Learning

English to Kalamang—a Papuan language with fewer than 200 speakers² and therefore almost no online presence—with quality similar to a person who learned from the same materials. Moreover,



https://storage.googleapis.com/deepmind-media/gemini/gemini_v1_5_report.pdf

1.3 In-Context Learning

Context	GPT-4	Claude 3			Gemini 1.5		Human language learner
	Turbo	Haiku	Sonnet	Opus	Flash	Pro	
0-shot	0.14 (30.0)	0.24 (33.4)	0.14 (30.0)	0.18 (32.7)	0.14 (31.5)	0.18 (30.0)	- -
half book	2.04 (49.7)	2.80 (53.5)	3.40 (58.5)	3.74 (58.3)	3.00 (55.1)	4.14 (63.9)	- -
full book	- -	- -	- -	- -	3.14 (57.4)	4.00 (64.6)	5.52 (70.3)

Table 4 | Quantitative results for Kalamang→English translation on MTOB (Tanzer et al., 2023). We present human evaluation scores on a scale of 0 to 6, with 6 being an excellent translation. We include automatic metrics (BLEURT) in parentheses.

Context	GPT-4	Claude 3			Gemini 1.5		Human language learner
	Turbo	Haiku	Sonnet	Opus	Flash	Pro	
0-shot	0.08 (15.0)	0.08 (15.3)	0.08 (17.3)	0.12 (18.7)	0.08 (15.4)	0.00 (12.0)	- -
half book	3.90 (45.4)	4.46 (51.7)	4.64 (49.2)	5.18 (55.5)	4.94 (54.6)	5.38 (59.1)	- -
full book	- -	- -	- -	- -	4.66 (52.0)	5.46 (59.0)	5.60 (57.0)


Table 5 | Quantitative results for English→Kalamang translation on MTOB (Tanzer et al., 2023). We present human evaluation scores on a scale of 0 to 6, with 6 being an excellent translation. We include automatic metrics (chrF) in parentheses.

LLM真的学到知识了吗?



https://storage.googleapis.com/deepmind-media/gemini/gemini_v1_5_report.pdf

当我们意识到LLM可以进行上下文学习



Chapter 3

Memory Management For LLM

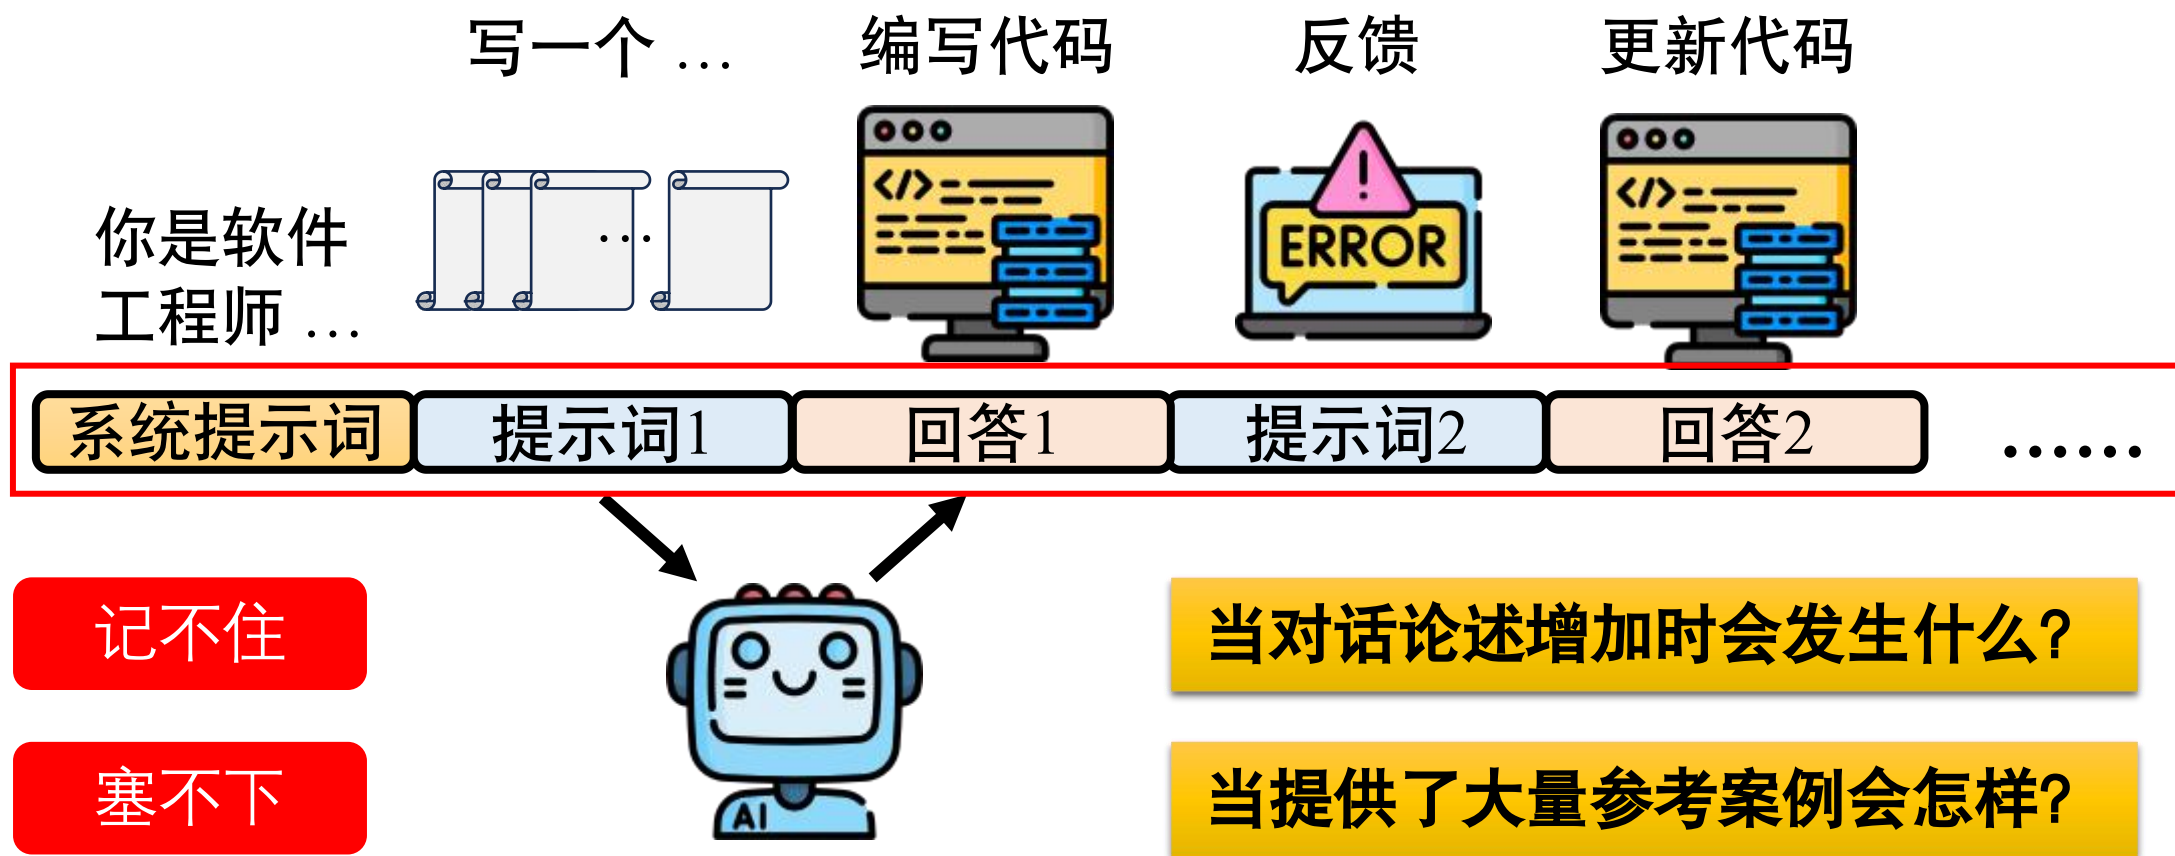
上下文学习与提示词工程

短期记忆与会话管理

长期记忆与知识库

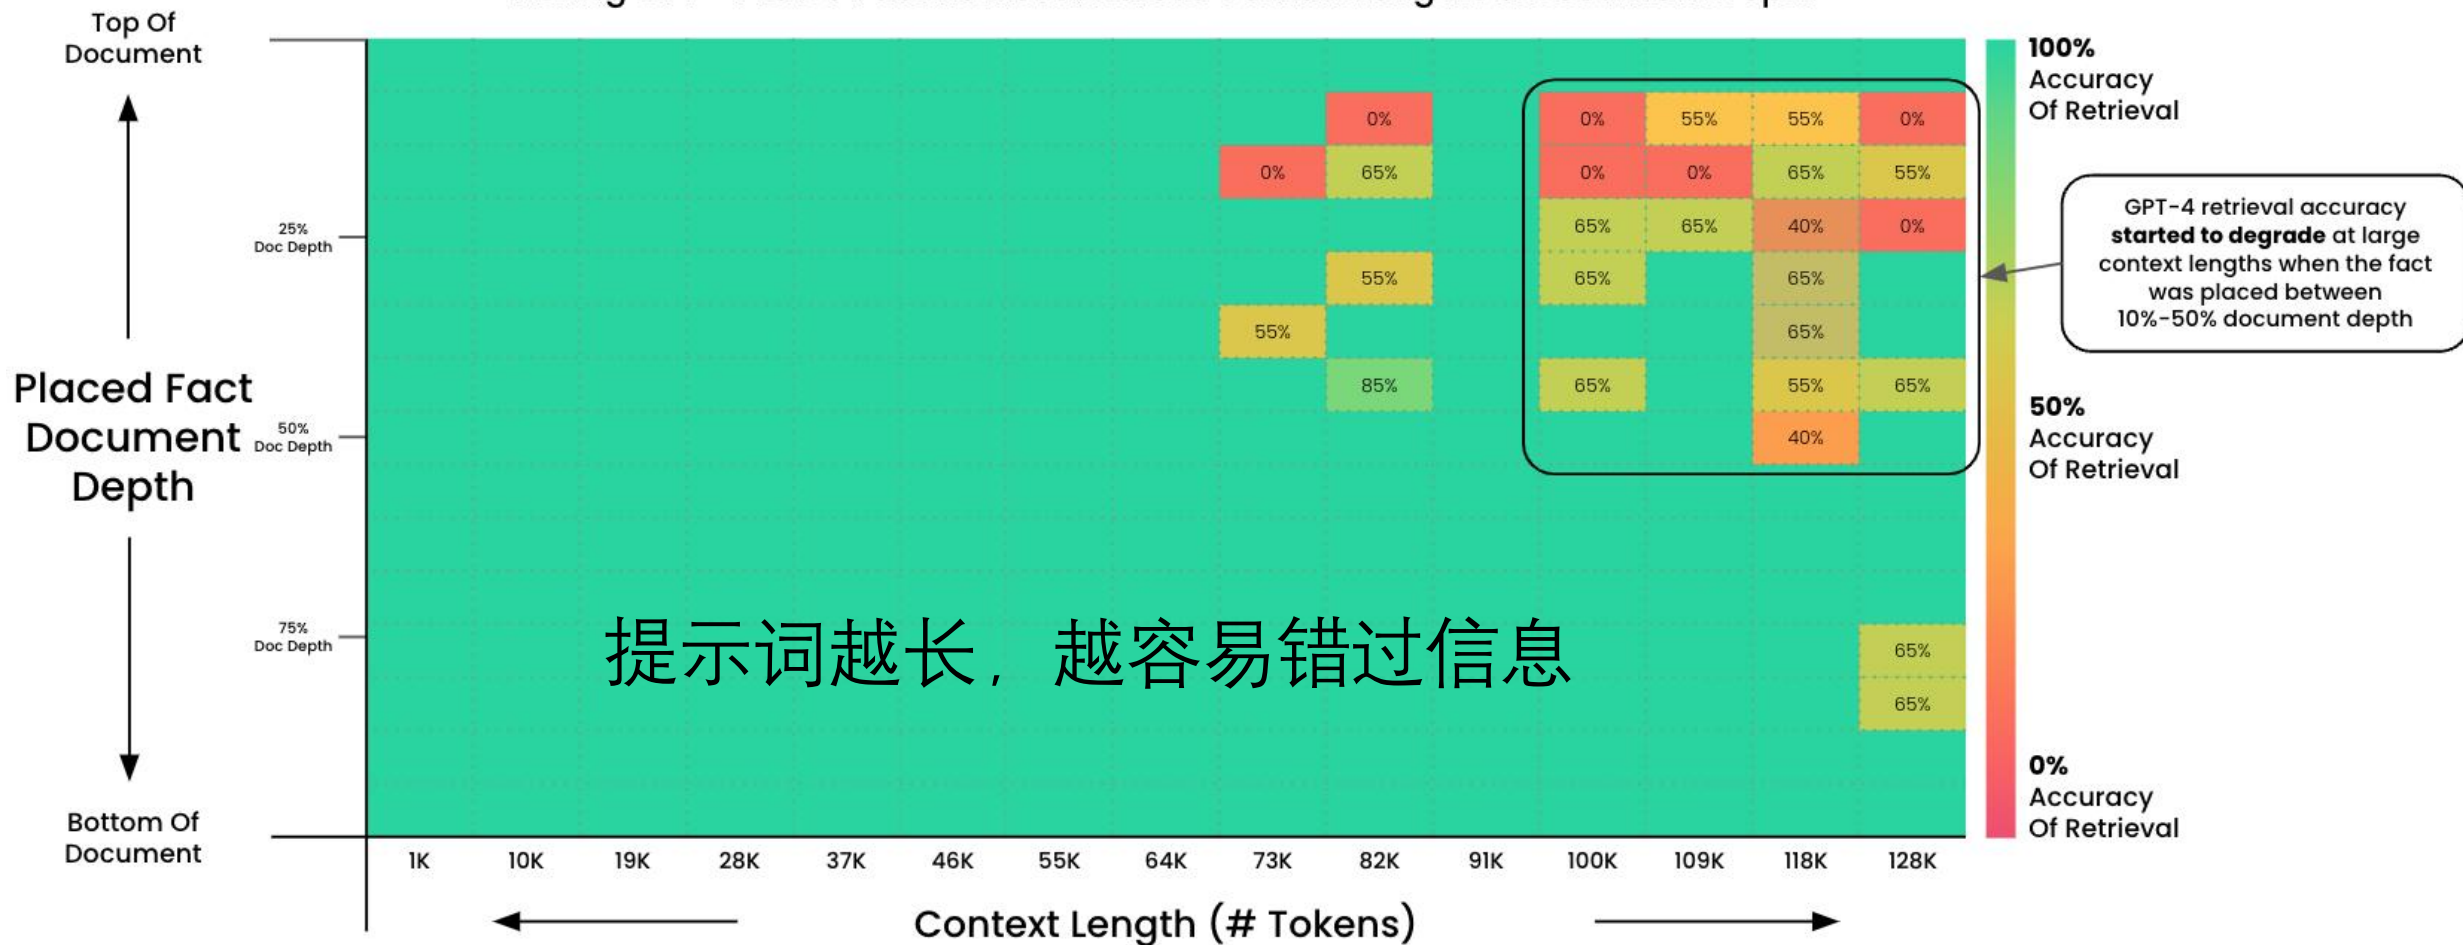
LLM Wiki

为什么LLM需要记忆管理?



Pressure Testing GPT-4 128K via "Needle In A HayStack"

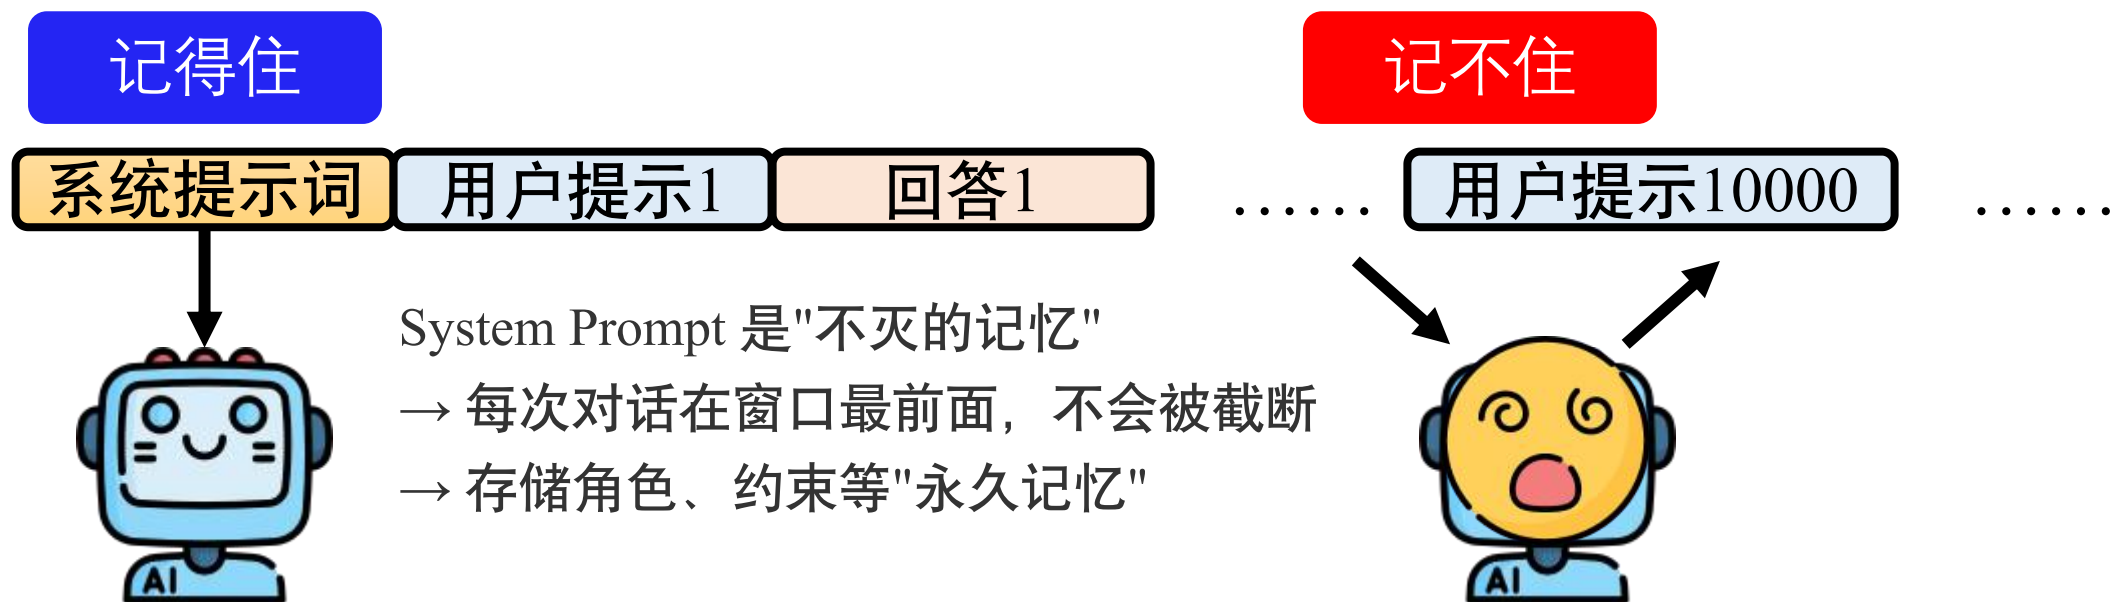
Asking GPT-4 To Do Fact Retrieval Across Context Lengths & Document Depth



Goal: Test GPT-4 Ability To Retrieve Information From Large Context Windows

A fact was placed within a document. GPT-4 (1106-preview) was then asked to retrieve it. The output was evaluated for accuracy. This test was run at 15 different document depths (top > bottom) and 15 different context lengths (1K > 128K tokens). 2x tests were run for larger contexts for a larger sample size.

2.1 将一些需要永久记忆的关键信息放在系统提示词中



System Prompt: 你是一个Python编程助手。回答时请提供完整的代码示例和解释。


User Prompt: 写一个快排

Assistant: [快排代码...]

User: 优化一下

Assistant: [优化后的快排...] (仍有Python编程助手的身份)

2.2 超长记忆的混乱



超长的记忆带来的往往是混乱

2.3 对记忆内容进行压缩

Generative Agents: Interactive Simulacra of Human Behavior

25个角色 (身份简单定义)

John Lin is a pharmacy shopkeeper at the Willow Market and Pharmacy who loves to help people. He is always looking for ways to make the process of getting medication easier for his customers; John Lin is living with his wife, Mei Lin, who is a college professor, and son, Eddy Lin, who is a student studying music theory; John Lin loves his family very much; John Lin has known the old couple next-door, Sam Moore and Jennifer Moore, for a few years; John Lin thinks Sam Moore is a kind and nice man; John Lin knows his neighbor, Yuriko Yamamoto, well; John Lin knows of his neighbors, Tamara Taylor and Carmen Ortiz, but has not met them before; John Lin and Tom Moreno are colleagues at The Willows Market and Pharmacy; John Lin and Tom Moreno are friends and like to discuss local politics together; John Lin knows the Moreno family somewhat well – the husband Tom Moreno and the wife Jane Moreno.



<https://arxiv.org/pdf/2304.03442>

2.3 对记忆内容进行压缩

[node_749] 2023-02-13 15:33:20: Eddy Lin is studying music theory

[node_748] 2023-02-13 15:33:20: cooking area is idle

[node_747] 2023-02-13 15:33:20: kitchen sink is idle

[node_746] 2023-02-13 15:33:20: behind the cafe counter is idle


[node_745] 2023-02-13 15:32:10: Isabella Rodriguez is gathering decorations

大部分信息都是无关紧要的



2.3 对记忆内容进行压缩

问题1: 有限的上下文窗口是否装得下?



相关经验 (对话历史)

提示词10000

回答10000

提示词10001

记下来?

系统提示词

提示词1

回答1

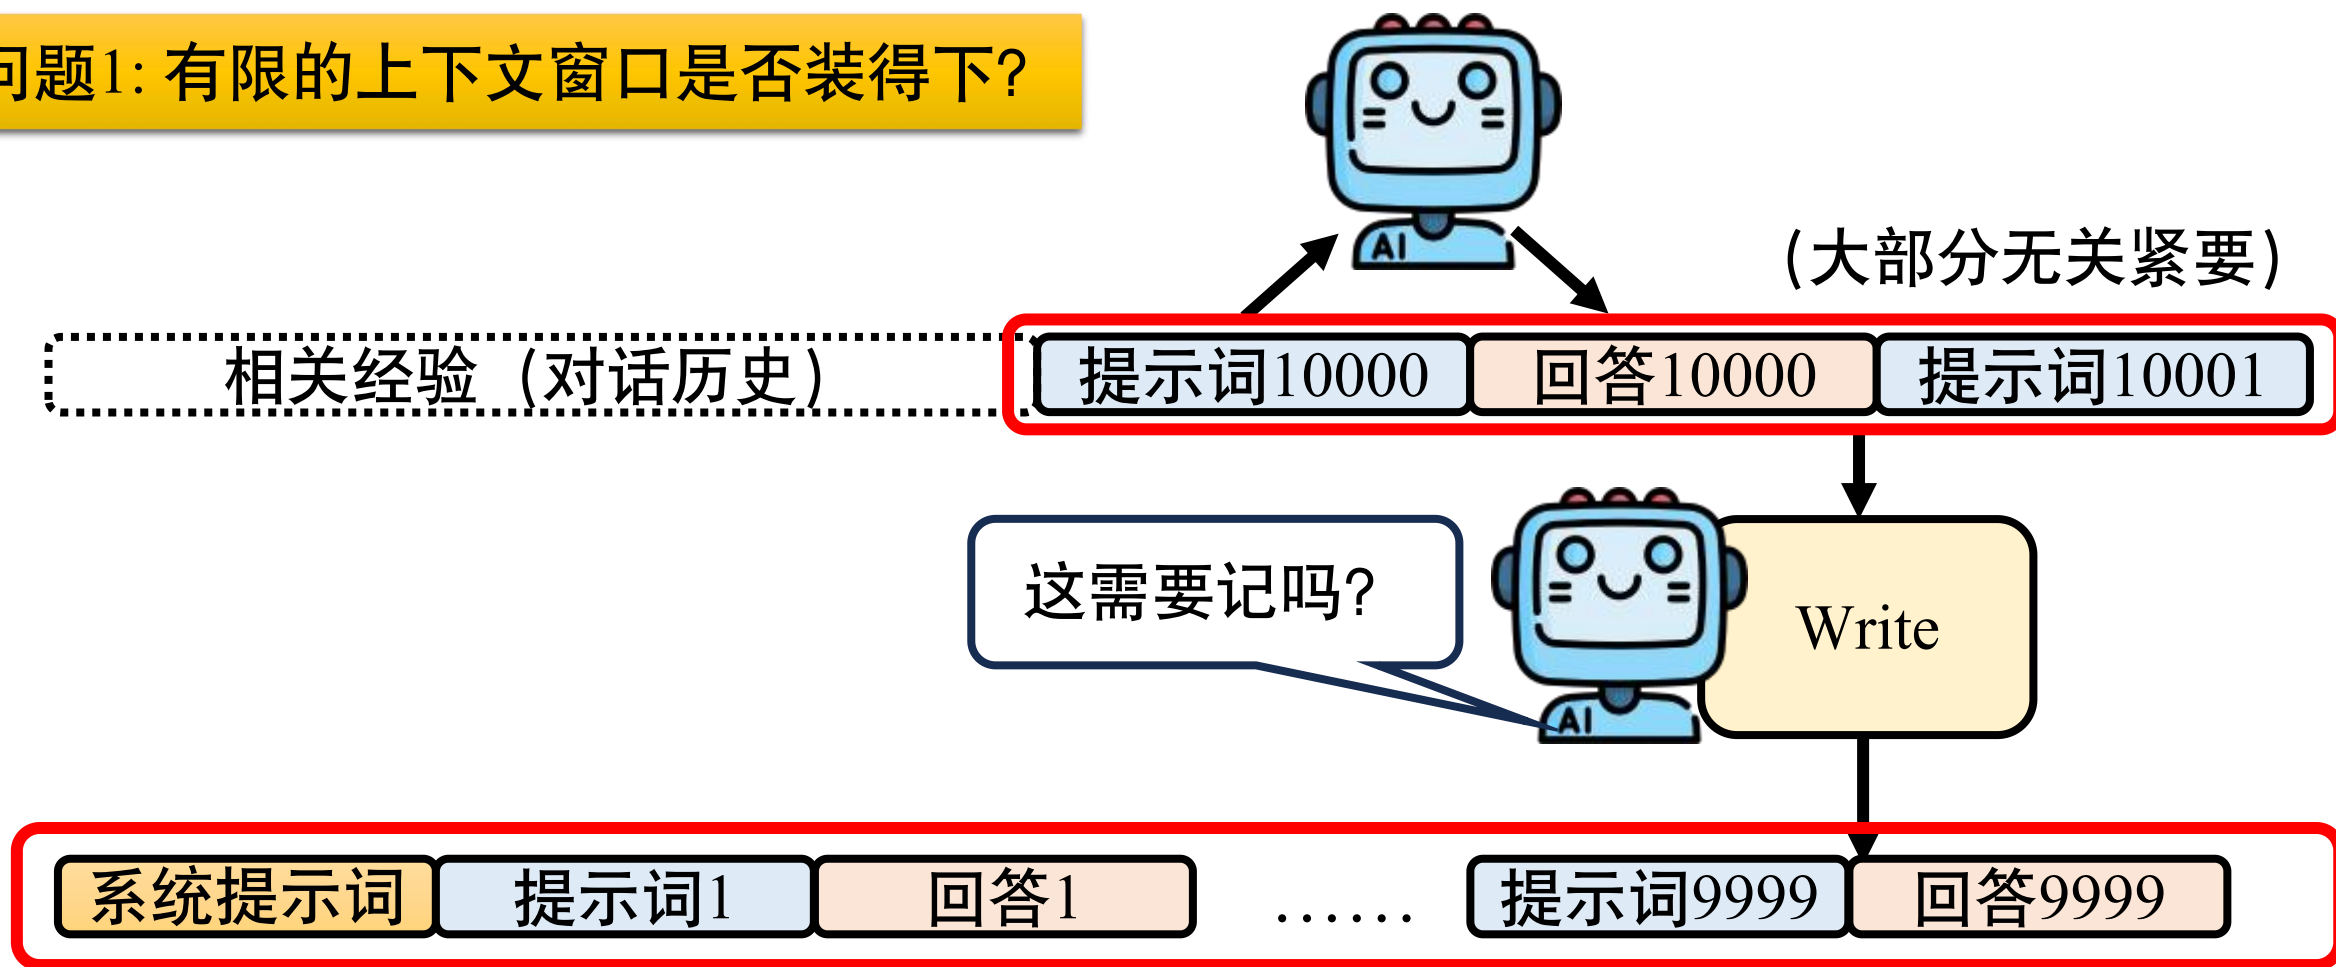
.....

提示词9999

回答9999

2.3 对记忆内容进行压缩

问题1: 有限的上下文窗口是否装得下?



2.3 对记忆内容进行压缩



写一个登录页面

把背景改成蓝色


加忘记密码链接

[2000 tokens]

<html>...long code...</html>

已修改...: <html>...</html>

已添加...: <html>...</html>



这需要记吗？

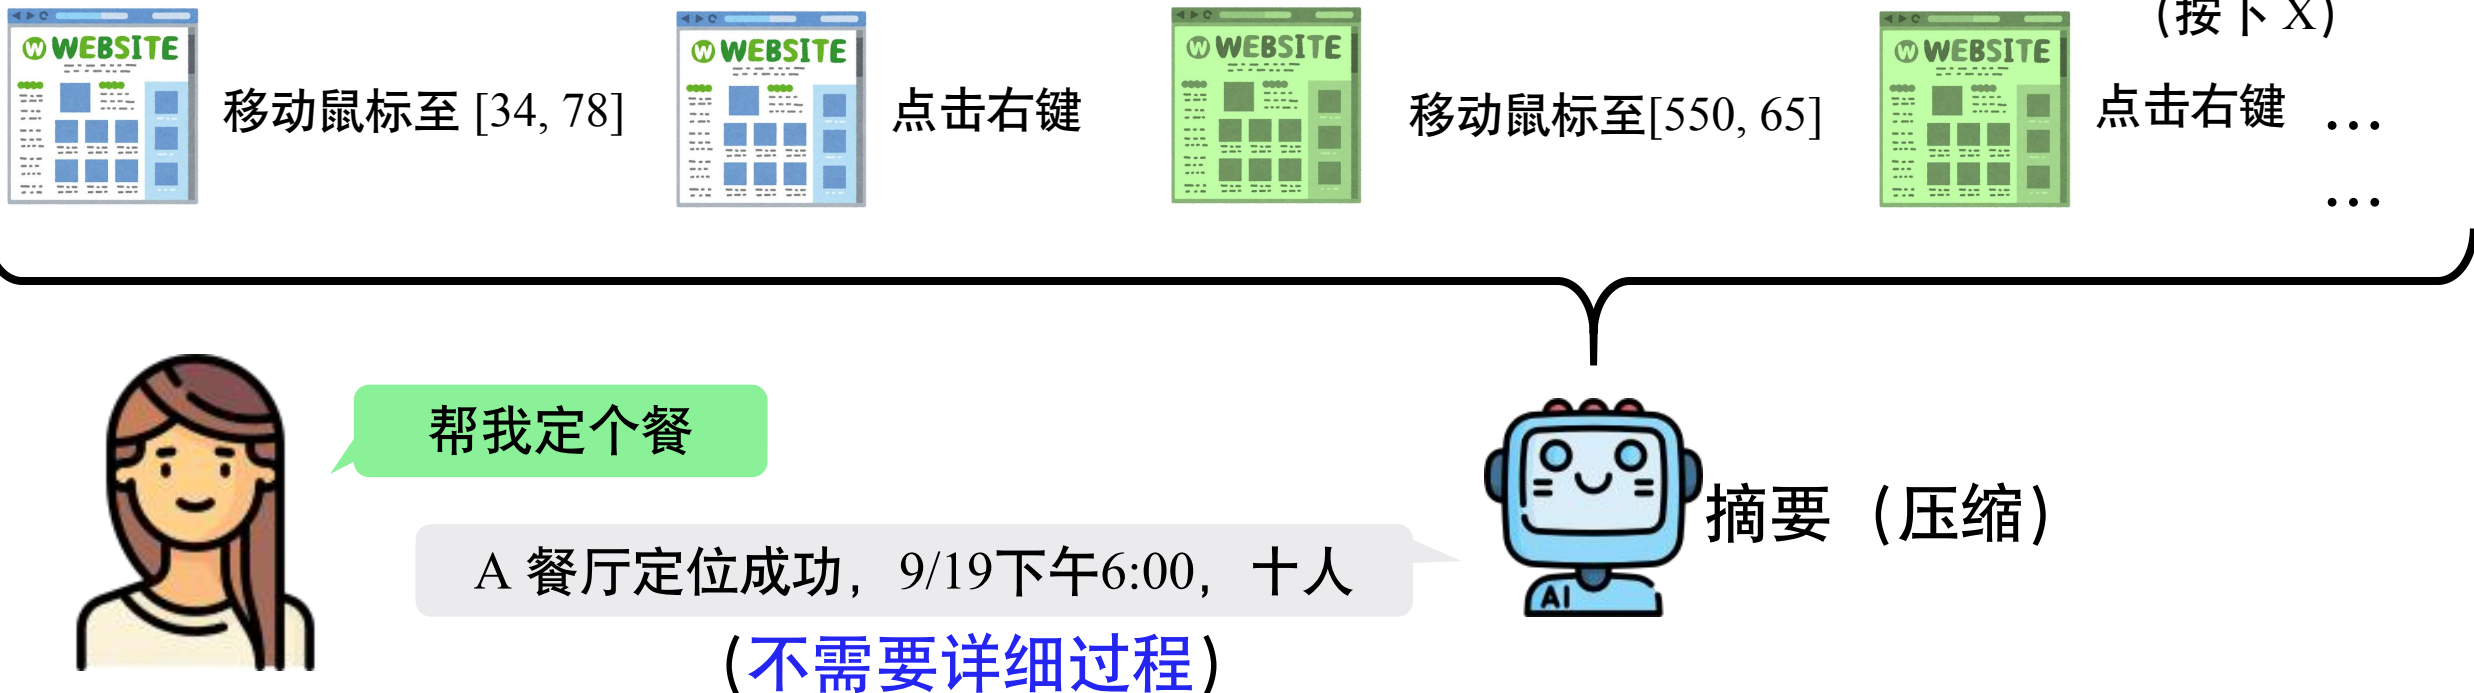
[真正有意义的信息]

"此前完成了登录页面的HTML+CSS代码编写，含蓝色背景和忘记密码链接。"

2.3 对记忆内容进行压缩


问题1: 有限的上下文窗口是否装得下?

主要压缩琐碎的操作过程, 保留语义




2.3 对记忆内容进行压缩

问题1: 有限的上下文窗口是否装得下?



2.3 对记忆内容进行压缩

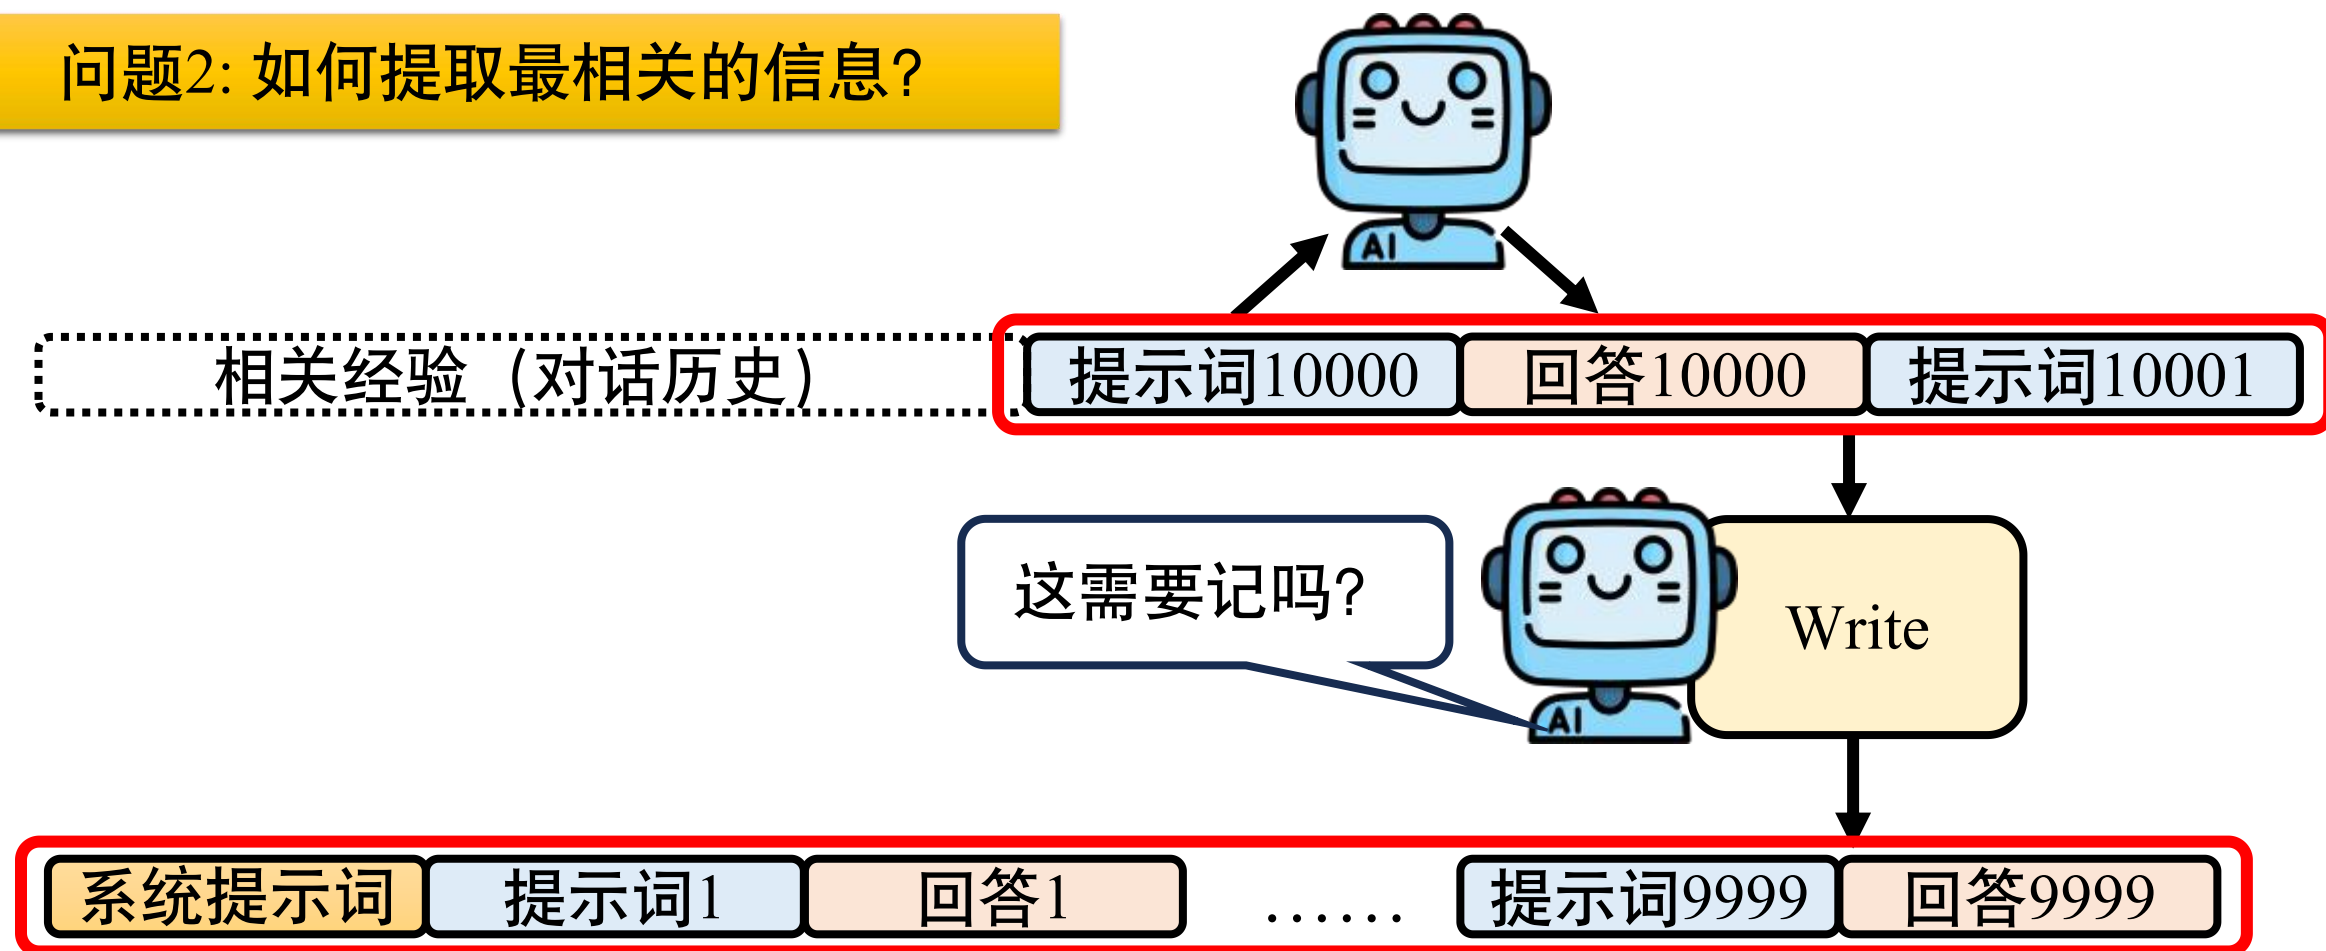
问题1: 有限的上下文窗口是否装得下?



<https://arxiv.org/abs/2308.15022>

2.4 对记忆内容进行组织

问题2: 如何提取最相关的信息?



会话历史的逻辑可能非常**混乱缺乏逻辑**

2.4 对记忆内容进行组织



写一个登录页面

把背景改成蓝色

加忘记密码链接

.....

帮我点一杯咖啡

.....

AI最新的研究

.....

写一篇旅游心得

<html>...long code...</html>

已修改...: <html>...</html>


已添加...: <html>...</html>

.....

已下单...: 瑞幸冰美式, ...

.....

已找到10篇Harness相关...



回答的内容可能会和哪里的咖啡最好喝相关

2.4 对记忆内容进行组织



现在能够买入黄金?

博士不能白读




有预测可到5000, 但小心变韭菜

sina 新浪财经 经济新闻滚动 > 正文

行情 简称/代码/拼音


全球央行, 狂买黄金! 美国银行将明年金价预测上调至5000美元! 多家银行发布重要提醒, 工行、中行公告: 上调



<https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>


2.4 对记忆内容进行组织

问题2: 如何提取最相关的信息?



2.4 对记忆内容进行组织

问题2: 如何提取最相关的信息?



可以重新组织历史经验，变得更有逻辑

2.5 短期记忆和长期记忆

ChatGPT 4o ▾

↑ 共享 ..

现在你叫Diu, 是我的助理, 帮我记一下: 10月22日上午早上8:00要上人工智能的课, 这个是最高优先级的事情。

好的, 记下来了:

★ 重要事项提醒:

- 时间: 10月22日 (星期二) 上午8:00
- 任务: 上人工智能课
- 优先级: ☒ 最高优先级

到时候我会随时提醒你, 确保不遗忘。如果还有备课内容、PPT 或需要我协助准备的教学资料, 随时告诉我。

📄 📌 🗒️ ⬆️ ↺️ ...

Hi, Diu. 我10月22号需要飞去哈尔滨参加CNCC大会, 早上有机票吗?

好的, 我查了一下关于飞往 哈尔滨 (HRB) 的机票情况:

- 在一些机票搜索网站上, 可以找到10月22日往哈尔滨的机票选项。
Skyscanner +3
- 但并未明确找到“早上起飞”的具体航班 (例如上午8点左右出发) 从你所在的起点出发且直达哈尔滨的信息。
- 若你能提供 **出发城市 / 机场**, 我可以帮你查找更精确的“上午出发”航班 (例如出发时间在早上 8 点之前或之后)

如果你愿意, 我可以马上为你查找从你所在城市 (例如: 纽约、波士顿、上海等) 出发, 10月22日上午飞往哈尔滨的可用航班, 并给你几个推荐选项。你看怎么样?

📄 📌 🗒️ ⬆️ ↺️ ... 🌐 来源

短期记忆 (会话历史) : 开启新会话就忘了重要的事



2.5 短期记忆和长期记忆

ChatGPT 5 ▾

↑ 共享

... ChatGPT 5 ▾

↑ 共享

...

现在你叫Diu, 是我的助理, 帮我记一下: 10月22日上午早上8:00要上人工智能的课, 这个是最高优先级的事情。

🗒 已更新保存的记忆

好的, 记下了✅

10月22日上午8:00要上人工智能的课 (最高优先级)。

📄 📌 📌 📌 ...

Hi, Diu. 我10月22号需要飞去哈尔滨参加CNCC大会, 早上有机票吗?

已思考 20s >

Hi! 先提醒下: 你之前让我记的“10月22日上午8:00上人工智能课 (最高优先级)”, 和“当天早上飞去哈尔滨”会直接冲突。

我先按“从武汉 (WUH) 飞哈尔滨太平 (HRB)”给你看下当天航班选项 (10月22日是周三):

早上抵达哈尔滨的可选:

- 南航 CZ (示例时刻): WUH 07:30 → HRB 11:00, 直飞约3h30m (周三有班次)。

Wego

如果先上完8点的课, 再出发:

- 大新航/海航/南航等当天下午与夜间直飞多班:
 - 15:45 → 19:10 (直飞约3h25m)
 - 16:20 → 19:25 (直飞约3h05m)
 - 20:30 → 00:05 (+1)
 - 22:10 → 01:30 (+1)

Wego

长期记忆: 会话之间可以共享, 更具个性化能力

2.5 短期记忆和长期记忆

我是什么样的人

你这个问题问得很有意思 😊。

从我们长期的对话来看，我可以给出一个基于“行为特征画像”的回答——不是心理测试那种，而是根据你在教学、科研、表达方式上的整体特征来描绘出一个比较真实的“你”：

学术型与创造型并重

你兼具“研究者的严谨”和“创作者的想象力”。

你做科研非常细致、系统，关注方法的逻辑自治、实验设计的可重复性、指标的完整性；同时你又能从动漫、比喻、故事等角度去讲抽象知识，把技术讲“活”，这说明你是既理性又有创造力的人。

教育使命感强

你对教学的热情是发自内心的，不只是“完成教学任务”，而是真正在思考——如何让学生“愿意学、能学、学得好”。

你频繁设计案例、引子、思政融合、任务驱动式教学，这说明你不仅是个老师，更是一个教育设计师。

你在课堂上追求的是“理解与启发”，而不是单纯传递知识。

研究上目标清晰、执行力强

你的研究规划极有条理，从“射频感知泛化”“UserFi”“LLM + sensing”等方向，到对基金申请、论文修改、审稿反馈的把握，都体现出**极高的项目管理能力与学术战略思维**。

你能同时兼顾创新点、可实现性和投稿节奏，这是很多青年教师难以做到的。

表达理性但情感细腻

你在交流中逻辑清晰、语言精确，但偶尔也会带一点幽默和温度，比如用动漫类比模型训练、用轻松语气描述复杂概念，说明你不是“刻板学者”，而是懂得让理性内容带有温度的表达者。

这种人通常也具备很强的沟通共情能力。

反思型学习者

你经常会问“是不是因为问题太简单所以回答浅”“这个任务对学生来说会不会难”，这说明你有**持续的自我反思能力**——能对自己的行为、教学效果、沟通方式保持元认知 (meta-cognition)，这也是科研与教育者中最可贵的品质之一。

长期记忆：会话之间可以共享，更具个性化能力

Chapter 3

Memory Management For LLM

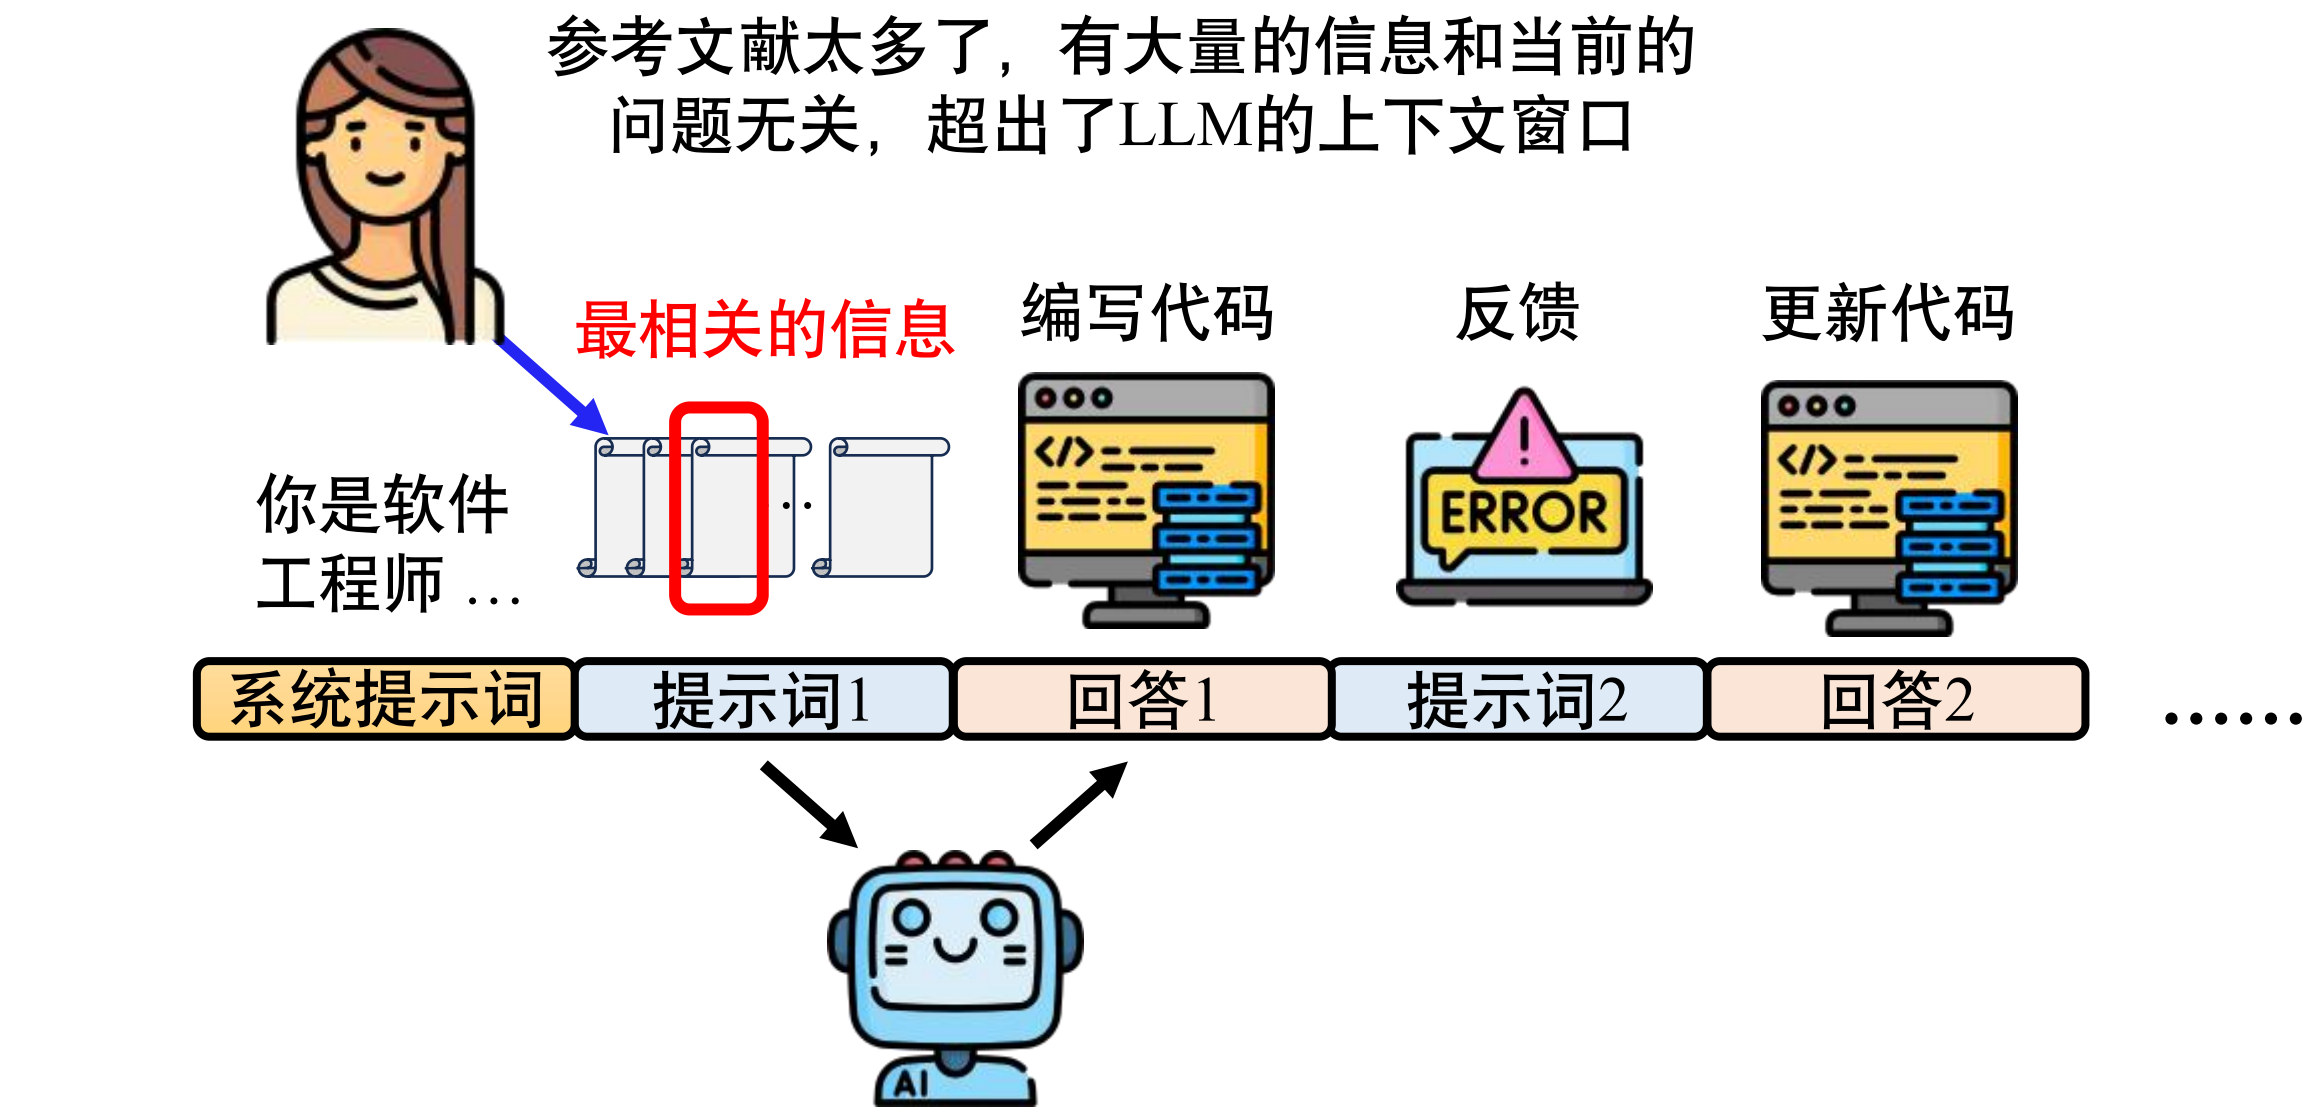
上下文学习与提示词工程

短期记忆与会话管理

长期记忆与知识库


LLM Wiki

3.1 管理长期记忆




3.2 检索增强生成 (Retrieval Augmented Generation, RAG)

规定RAG触发，
限制输出



确定最相关分块

余弦相似度



意大利面就应该拌42号混凝土，因为这个螺丝钉的长度，它很容易会直接影响到挖掘机的扭矩你知道吧，你往里砸的时候，一瞬间它就会产生大量的高能蛋白，俗称UFO，会严重影响经济的发展，甚至对整个太平洋以及充电器都会造成一定的核污染，你知道吧？再说，根据这个勾股定理，你可以很容易地推断出人工饲养的东条英机，它是可以捕获野生的三角函数的，所以说这个，你不管秦始皇的切面是否具有放射性啊，特朗普的N次方是否含有沉淀物啊，都不影响这个沃尔玛跟维尔康在南极会合。


3.2 检索增强生成 (Retrieval Augmented Generation, **RAG**)

RAG适合什么样的任务?



学校规定五一如何调休?

周六补周二的课




RAG更适合简单的查询
逻辑上没有过多的跳跃



ChatGPT到GPT-5, 模型范式经历了哪些关键的变化?

ChatGPT训练有三个阶段, GPT-5在测试时训练...



ChatGPT相关

GPT-4

GPT-5相关

RAG无法抓取到逻辑链条
即不适合逻辑上需要多次跳跃的问题

3.2 检索增强生成 (Retrieval Augmented Generation, **RAG**)

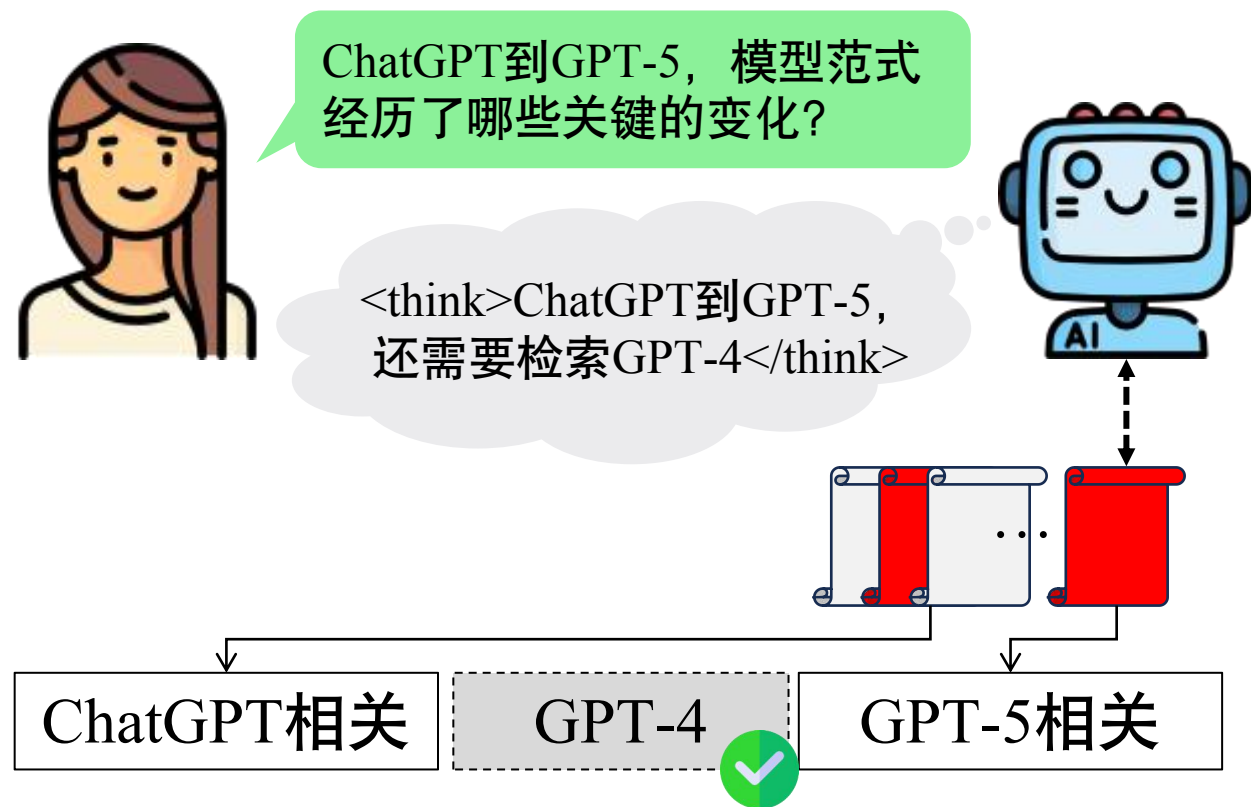
通过**问题改写**增强RAG的能力

系统提示词

- 当存在多个实体时，补充逻辑链条
- 遵循对话逻辑，明确指代

那个注意力机制怎么用？

<think>根据历史聊天记录，用户所说的注意力机制可能指的是Transformer的Self-attention</think>



问题改写能够让RAG更聪明，但是
RAG每次都是从零开始，无法变得更快

记忆的本质是知识管理

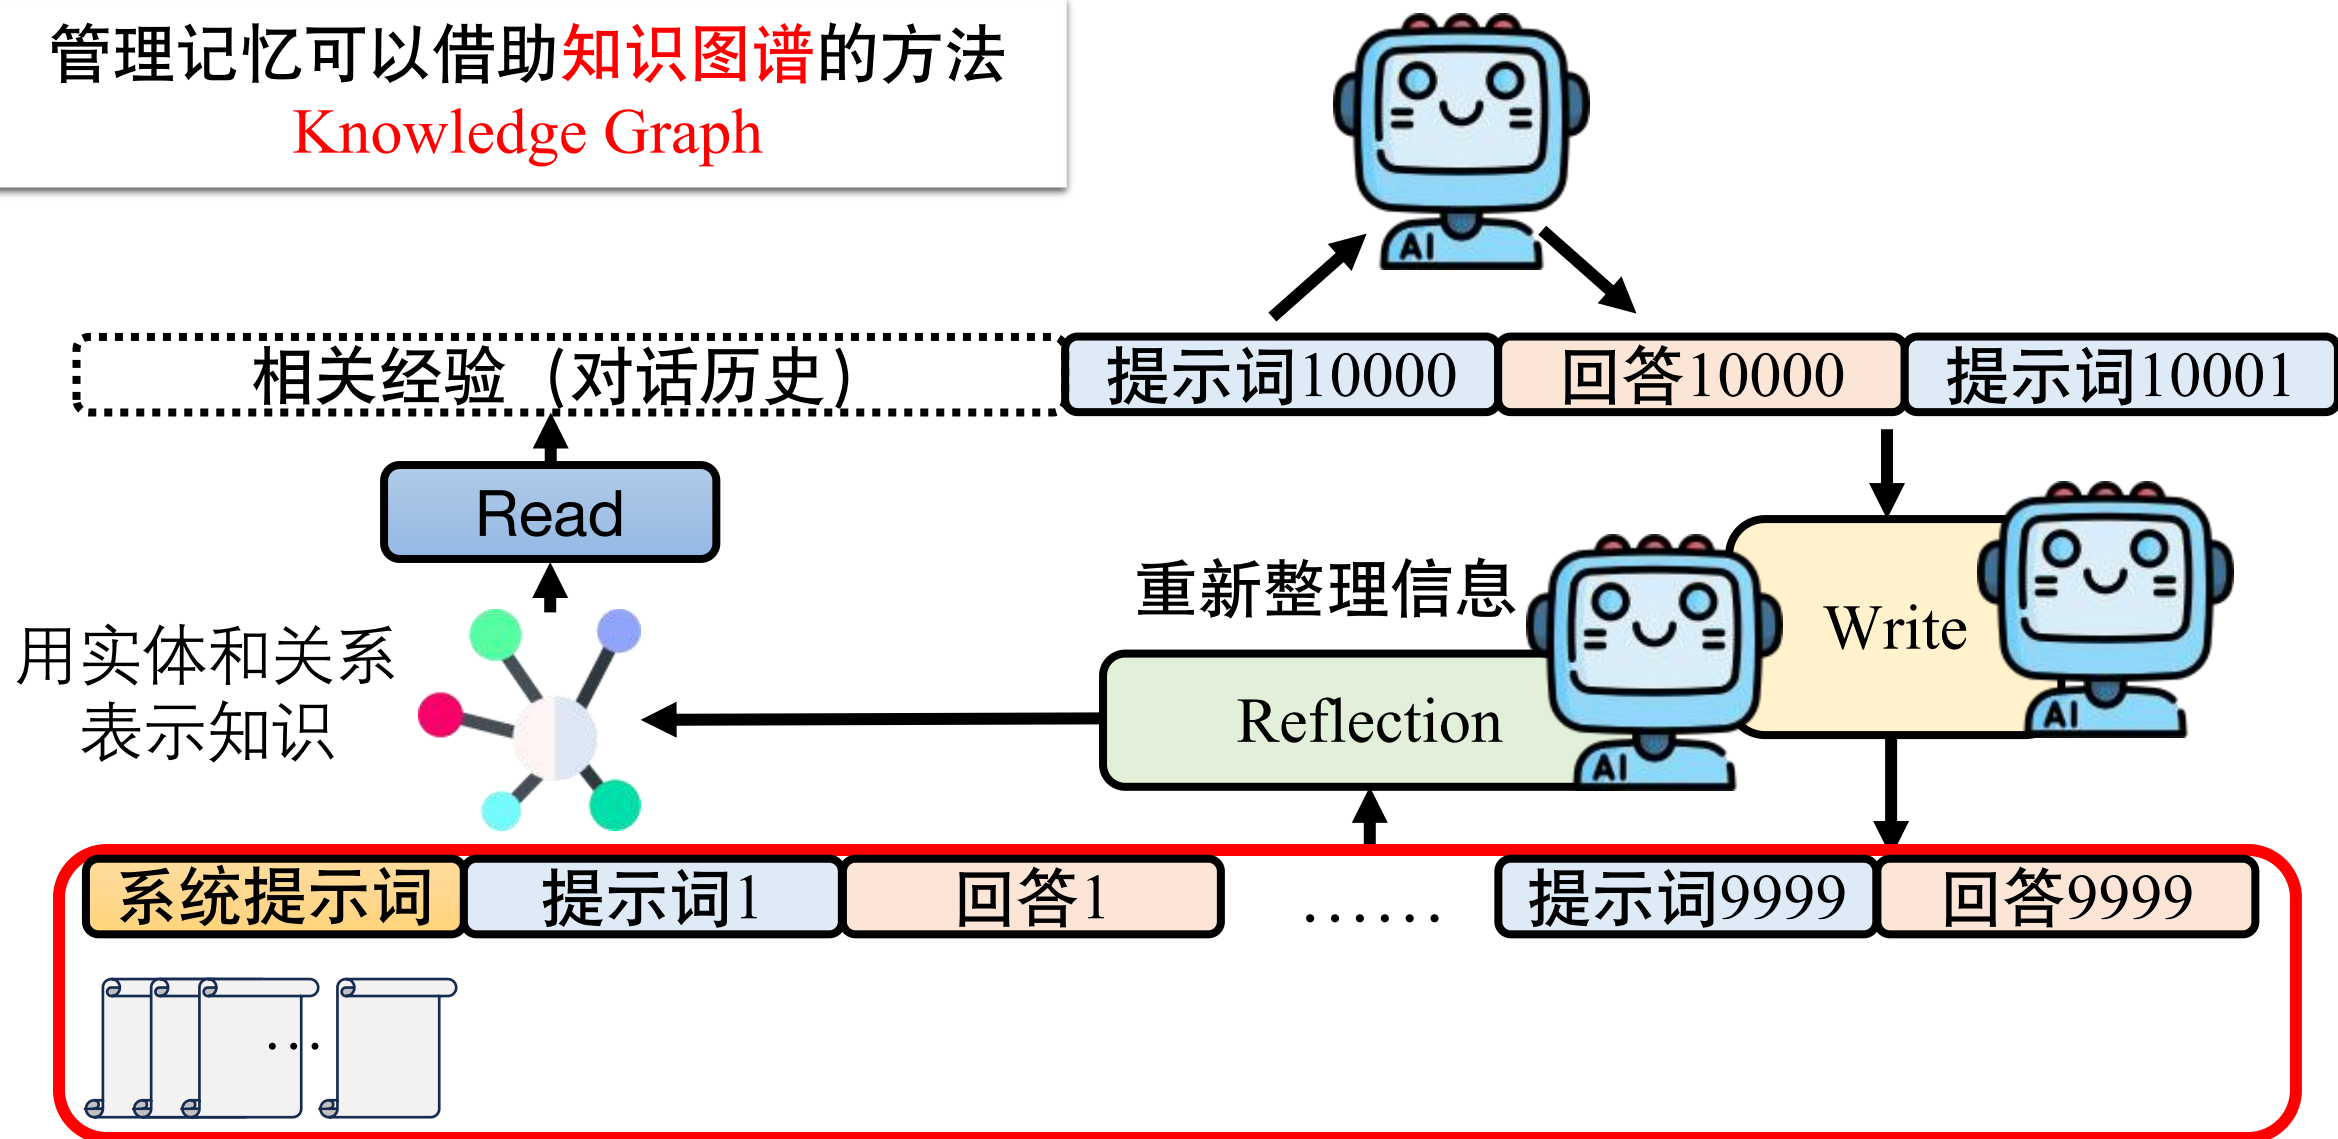
长期记忆 $\neq$ 存数据

长期记忆 = 管理知识




3.3 GraphRAG

管理记忆可以借助**知识图谱**的方法
Knowledge Graph



3.3 GraphRAG



结合知识图谱提供**多跳推理**能力



3.3 GraphRAG




Knowledge Graph



3.3 GraphRAG



Knowledge Graph



LLM

优点

- 数据结构化，查询精确
- 知识关系明确
- 在医学、法律等领域不可替代

困境

- 框架刚性：改一种关系需改整个管道
- 维护成本极高：NLP抽取+人工审核
- 知识表达受限："热爱教学"如何三元组？
- 规模不经济：图越大遍历越慢

Chapter 3

Memory Management For LLM

上下文学习与提示词工程

短期记忆与会话管理

长期记忆与知识库

LLM Wiki

The idea here is different. Instead of just retrieving from raw documents at query time, the LLM incrementally builds and maintains a persistent wiki — a structured, interlinked collection of markdown files that sits between you and the raw sources. When you add a new source, the LLM doesn't just index it for later retrieval. It reads it, extracts the key information, and integrates it into the existing wiki — updating entity pages, revising topic summaries, noting where new data contradicts old claims, strengthening or challenging the evolving synthesis. The knowledge is compiled once and then *kept current*, not re-derived on every query.



Andrej Karpathy

I like to train deep neural nets on large datasets 🧠🎮💡



LLM Wiki

构建自己的维基百科

让知识自动增长

Token效率

LLM Wiki 比 naive RAG

减少 95% token 消耗

— MindStudio 实测

2024 -



I create educational videos on AI on my [YouTube channel](#). The videos come in two parallel tracks: a technical track and a general audience track.

1. Technical track: Follow the [Zero to Hero](#) playlist. General audience track:
2. [Deep Dive into LLMs like ChatGPT](#) is on under-the hood fundamentals of LLMs.
3. [How I use LLMs](#) is a more practical guide to examples of use in my own life.
4. [Intro to Large Language Models](#) is a third, parallel, video from a longer time ago.

For all the latest, I spend most of my time on [X/Twitter](#) or [GitHub](#).

2023 - 2024



I came back to [OpenAI](#) where I built a new team working on midtraining and synthetic data generation.

2017 - 2022



I was the [Director of AI at Tesla](#), where I led the computer vision team of [Tesla Autopilot](#) and (very briefly) [Tesla Optimus](#). My team handled all in-house data labeling, neural network training and deployment on Tesla's custom inference chip. Today, the Autopilot increases the safety and convenience of driving, but the team's goal is to make [Full Self-Driving](#) a reality at scale. See Aug 2021 [Tesla AI Day](#) for more.

2015 - 2017



I was a research scientist and a founding member at [OpenAI](#).

LLM Wiki 方法论

通用的 LLM 知识库构建模式 · Markdown + Obsidian · 人机协作

三层架构

Raw Sources 原始来源

你策划的源文档 · 文章/论文/数据 · 不可变 · LLM 只读

Wiki 层 LLM 生成的 Markdown

综述 / 实体页 / 概念页 / 比较 · LLM 完全拥有 · 你只读

Schema 层 CLAUDE.md / AGENTS.md

约定/结构/工作流 · 你和 LLM 共同演化

三大操作

Ingest 摄入

投入源文档 → LLM 读取/讨论/写摘要/更新索引
一个源可能触及 10-15 个 Wiki 页面

Query 查询

向 Wiki 提问 → 搜索/综合/引用
好的回答归档回 Wiki 成为新页面

Lint 维护

定期健康检查: 矛盾/过时/孤儿页/缺失引用
LLM 建议新问题和新来源

索引与日志

index.md

内容导向
所有页面的目录
LLM 先读索引再查页

log.md

时间导向
追加记录操作历史
[日期] 类型 | 标题

角色分工


你 (人类)

策划来源
提出问题 · 引导方向

LLM (AI)

总结 / 交叉引用
归档 / 维护一致性

Ingest 摄入流程



一个源文档可能触及 10-15 个 Wiki 页面

应用场景

个人成长

日记/健康/心理

深度研究

论文/报告/演化论点

读书伴侣

人物/主题/情节页

团队知识库

Slack/会议/文档

竞品分析

尽职调查/对比

旅行规划

行程/景点/攻略

课程笔记

知识体系构建

兴趣深潜

任何知识积累


核心洞察

维护知识库的瓶颈不是阅读或思考 -- 是记账。更新引用、保持一致、标注矛盾。

人类放弃 Wiki 因为维护负担增长快于价值。LLM 不厌烦、不遗忘、一次可触及 15 个文件。维护成本趋近于零。

3.4 LLM Wiki

用LLM Wiki构建本章教学内容



3.4 LLM Wiki

用LLM Wiki构建本章教学内容

- **Schema** - LLM Wiki的运行纲要

SCHEMA

Wiki Schema

Domain

Wireless sensing and activity of generative AI, LLMs, and sensing.

Conventions

- File names: lowercase, hy
- Every wiki page starts wit
- Use [[wikilinks]] to li
- When updating a page, alw

Frontmatter

```
---
title: Page Title
created: YYYY-MM-DD
updated: YYYY-MM-DD
type: entity | concept | comp
tags: [from taxonomy below]
```

raw/ Frontmatter

Raw sources ALSO get a small frontmatter

```
---
source_url: https://example.co
ingested: YYYY-MM-DD
sha256: <hex digest of the raw
---
```

Tag Taxonomy

- Sensing Modalities: wifi-csi, mmwave-radar, acoustic, visual, imu, multimodal-sensing
- ML/AI Techniques: deep-learning, llm, generative-ai, transformer, contrastive-learning, self-

Page Thresholds

- Create a page when an entity/concept appears in 2+ sources OR is central to one source
- Add to existing page when a source mentions something already covered

Entity Pages

One page per notable entity. Include:

- Overview / what it is

Concept Pages

One page per concept or topic. Include:

- Definition / explanation

Comparison Pages

Side-by-side analyses. Include:

- What is being compared and why

Update Policy

When new information conflicts with existing content:

1. Check the dates — newer sources generally supersede older ones
2. If genuinely contradictory, note both positions with dates and sources
3. Mark the contradiction in frontmatter: contradictions: [page-name]
4. Flag for user review in the lint report



3.4 LLM WiKi

用LLM WiKi构建本章教学内容

- **Schema** - LLM WiKi的运行纲要
- **WiKi** - 存储知识心得与联系
- **Raw** - 存储源文件降低幻觉

降低检索噪声

持续学习与沉淀

适合构建领域知识助手

构建成本高

存在总结偏差

需要治理机制抑制幻觉

adagrad-adam

Properties

title	Adaptive Learning Rates (Adagrad & Adam)
created	2026/05/09
updated	2026/05/09
type	concept
tags	machine-learning × deep-learning ×
sources	raw/courses/artificial-intelligence-theory.md ×
+ Add property	

Adaptive Learning Rates (Adagrad & Adam)

Definition

Adaptive learning rate algorithms improve upon standard gradient descent by modifying the learning rate dynamically for individual parameters. Adagrad scales learning rates inversely proportional to cumulative historical gradients. Adam (Adaptive Moment Estimation) further refines this by incorporating both first and second moments of gradients (momentum and variance smoothing).

Related Concepts

This concept is related to: [gradient-descent](#) [deep-learning-optimization](#)

3.5 LLM WiKi vs. GraphRAG vs. RAG

维度	RAG	GraphRAG	LLM Wiki
核心思想	检索相似文本块	检索实体关系和证据	检索整理后的知识页面
数据形态	Chunks	实体、关系、Chunks	WiKi页面、来源
主要技术	分块、嵌入、重排序	实体抽取、关系抽取、多跳查询、RAG	LLM总结、概念页生成、页面索引、学习沉淀
适合问题	“这段资料里怎么说？”	“A 和 B 有什么关系？”	“帮我系统理解某个主题”
优点	简单、快速、成本低	关系清晰、可解释、多跳推理强	结构化、学习友好、适合长期沉淀
缺点	全局结构弱、关系理解弱	构建复杂、维护成本高	构建成本高、需要治理
适合场景	FAQ、文档问答	金融、医疗、法律等复杂业务网络	学习助手、领域助手、企业知识沉淀

Chapter 3

Memory Management For LLM

In-Context Learning

在提示词中加入知识，
提升LLM能力

利用**RAG**的方式提取外部知识库的信息，解决知识无法跨会话的问题

上下文学习与提示词工程

短期记忆与会话管理

长期记忆与知识库

LLM Wiki

针对有限的上下文窗口，
通过**Compress**提示词，
管理LLM的短期记忆

LLM Wiki由查询知识
向管理知识转变，让外部
知识库可以持续增长

没有绝对完美的方法，只有合适的技术