

Chapter 5

Agents & Skills & Context Engineering

什么是智能体

智能体的核心能力

上下文工程

智能体的Skills




1.1 什么是 AI Agent ?

以前使用 AI 的方式

用户给与明确的**指令**


AI 一个指令一个动作



AI Agent

用户给与**目标**

AI 自己想办法达成



需要多步骤、灵活调整计划

1.1 什么是 AI Agent ?


AI Agent 的定义仍然存在争论

扣子, 用 Agent 重塑生产力

低门槛 | 灵活编排 | 全链路评测 | 安全可靠 | 开箱即用



工作流 (Workflow) 也可以是 Agent



1.1 什么是 AI Agent ?


AI Agent 的定义仍然**存在争论**




有人认为 Agent 必须有物理载体，即具身智能

本节课不参与定义的讨论，而仅仅关注背后的**共性**

1.2 曾经的 Agent




1.2 曾经的 Agent




这其实就是Reinforcement Learning (RL)，即强化学习
Agent的概念其实很早就有了


1.2 曾经的 Agent



1.2 曾经的 Agent



1.2 曾经的 Agent




1.2 曾经的 Agent




局限：为每一个任务设计并训练专用的RL模型

1.3 基于 LLM 的 Agent



以LLM直接构建通用的Agent——**AGI**（通用人工智能）

1.3 基于 LLM 的 Agent



以LLM直接构建通用的Agent——**AGI**（通用人工智能）

1.4 LMM-based AI Agent 的一些应用场景

模拟虚拟社会（游戏）

Generative Agents: Interactive Simulacra of Human Behavior


<https://arxiv.org/pdf/2304.03442>

25个角色（身份简单定义）

John Lin is a pharmacy shopkeeper at the Market and Pharmacy who loves to help people. He is always looking for ways to make the process of getting medication easier for his customers. John Lin is living with his wife, Mei Lin. Mei Lin is a college professor, and son, Eddy Lin is a student studying music theory; John Lin loves his family very much; John Lin has known a couple next-door, Sam Moore and Jennifer Moore for a few years; John Lin thinks Sam Moore is a kind and nice man; John Lin knows his neighbor Yuriko Yamamoto, well; John Lin knows his neighbors, Tamara Taylor and Carmen Ortiz. He has not met them before; John Lin and Tom Moreno are colleagues at The Willows Market and Pharmacy. John Lin and Tom Moreno are friends and discuss local politics together; John Lin knows the Moreno family somewhat well – the husband, Tom Moreno and the wife Jane Moreno.



1.4 LMM-based AI Agent 的一些应用场景



1000 AI NPCs simulate a CIVILIZATION in Minecraft

<https://www.youtube.com/watch?v=2tbaCn0Kl90>

1.4 LMM-based AI Agent 的一些应用场景

解放人类双手



1.4 LMM-based AI Agent 的一些应用场景

Computer Use



 哈尔滨三日游行程规划 (10月22日 - 10月25日)
最后修改时间：刚刚

🔗 分享

📄 下载

⋮ 更多

哈尔滨三日游行程规划 (10月22日 - 10月25日)

会议地点： 南岗区贵新街 **出行时间：** 2025年10月22日抵达，10月26日一早返程 **游玩时间：** 每天晚上有空，下午有1-2天有空 **兴趣偏好：** 美食、自然风光

天气提示与着装建议： 根据查询，10月下旬哈尔滨的气温通常在零下几度到零上几度之间，昼夜温差较大。例如，10月22日至25日期间，白天最高气温可能在3-7°C左右，夜间最低气温可能在-3到-5°C左右。天气以晴或多云为主，降水较少。鉴于此，建议您务必准备充足的保暖衣物，包括羽绒服或厚外套、保暖内衣、毛衣或抓绒衣、厚裤子（如加绒牛仔裤或冲锋裤）、围巾、帽子、手套以及防滑保暖的雪地靴或厚底运动鞋，以应对哈尔滨深秋的寒冷气候。

第一天：10月22日 (周三) - 抵达与中央大街夜景

您抵达哈尔滨后，建议首先前往预订的酒店办理入住手续。考虑到会议地点在南岗区贵新街，选择南岗区或道里区的酒店将更为便利，以便于会议和后续的游玩安排。下午时段您可以进行会议报到或稍作休息，为晚上的行程养精蓄锐。

晚上约18:00开始，您可以从南岗区贵新街出发，乘坐地铁2号线或选择打车前往著名的**中央大街**。这条拥有百年历史的商业街，汇聚了多种欧式建筑风格，夜晚在璀璨灯光的映衬下更显其独特的异域魅力。您可以在这里漫步，感受浓厚的俄罗斯风情，欣赏街头艺术。晚餐推荐在中央大街附近品尝哈尔滨特色美食，例如可以尝试**老厨家**（锅包肉的发源地之一），或者体验**华梅西餐厅**（一家历史悠久的俄式西餐馆，但可能需要排队）。此外，即使天气寒冷，也强烈推荐品尝一支**马迭尔冰棍**，这是中央大街的标志性小吃。餐后，您可以步行至距离中央大街不远的**圣索菲亚大教堂**，欣赏这座宏伟的拜占庭式建筑在夜幕下的独特光影，是绝佳的拍照留念地点。

交通建议： 从南岗区贵新街乘坐地铁2号线可直达中央大街附近的中央大街站或防洪纪念塔站，交通十分便捷。

<https://manus.im/>

1.4 LMM-based AI Agent 的一些应用场景

Computer Use

 manus

新建任务

搜索

库

所有任务

哈尔滨3天会议期间轻松游玩计划

Manus 1.5 Lite

哈尔滨三日游行程规划 (最后修改时间: 刚刚)

哈尔滨

会议地点:
有空, 下午

天气提示与
较大。例如
左右。天气
外套、保暖
的雪地靴或

第一天:
您抵达哈尔
岗区或道里
作休息, 为
晚上约18:0
条拥有百年
力。您可以
滨特色美食
式西餐馆,
的标志性小
建筑在夜幕

交通建议:
十分便捷。

哈尔滨三日游行程规划

10月22日 - 10月25日 | 轻松游玩, 品尝美食, 感受自然

会议地点

南岗区贵新街

出行时间

10月22日抵达, 10月26日一早返程

游玩时间

每天晚上有空, 下午有1-2天有空

兴趣偏好

美食、自然风光

天气提示与着装建议

10月下旬哈尔滨气温较低, 白天最高温3-7°C, 夜间最低温-3到-5°C, 昼夜温差大。天气以晴或多云为主, 降水较少。请务必准备充足的保暖衣物: 羽绒服或厚外套、保暖内衣、毛衣或抓绒衣、厚裤子、围巾、帽子、手套以及防滑保暖的雪地靴或厚底运动鞋。

第一天: 10月22日 (周三) - 抵达与休整

下午


抵达与办理入住

您将在下午或晚上抵达哈尔滨。建议首先前往预订的酒店办理入住手续。考虑到会议地点在南岗区贵新街, 选择南岗区

<https://manus.im/>

1.4 LMM-based AI Agent 的一些应用场景

Training Model



AIDE: The Machine Learning Engineer Agent

AutoKaggle: A Multi-Agent Framework for Autonomous Data Science Competitions

<https://arxiv.org/abs/2502.13138>

<https://arxiv.org/abs/2410.20424>

Chapter 5

Agents & Skills & Context Engineering

什么是智能体


智能体的核心能力

上下文工程


智能体的Skills




智能体应该具备哪些能力？



2.1 Agent 能感知什么？




2.1 Agent 能感知什么？



如何构建多模态模型？


关键在于 Tokenizing 和 Embedding



2.2 LLM 一定程度上具备理解多模态信息的能力



Conventional applications of LLM



Penetrative LLM for physical world tasks

LLM的传统引用是文本处理

当提供专业的知识和物理数值
就可渗透物理世界
Penetrative AI

<https://arxiv.org/pdf/2310.09605>

2.2 LLM 一定程度上具备理解多模态信息的能力

Query Sensor Data

- 1. Step count: 105.0/min.
- 2. Satellites detected: 0. Carrier-to-noise: 0.0dB.
- 3. Total WiFi APs scanned: 31. SSID list: ['EastPointCity', 'WiFi.HK via EPCC', '3DG Jewellery', '3HK Pro3 5G', '5G私家寬頻', 'citicall01', 'CSL WiFi-Roam', 'H158-381_6c49', 'CENTALINE FREE WIFI', 'MiHome', 'SASA_LIVE', '_BWSHOP_', ...]



Shopping Mall, Hong Kong

Response from ChatGPT-4

Reasoning:

- 1. Step count: 105.0/min. The high step count indicates that the user is likely walking, suggesting movement and active state.
- 2. Satellites detected: 0. Carrier-to-noise: 0dB. The absence of detected satellites and a carrier-to-noise ratio of 0 dB strongly suggest that the user is in an indoor environment, as satellite signals are usually weak or non-existent indoors.
- 3. Total WiFi APs scanned: 31. The detection of 31 WiFi Access Points supports the inference of an indoor environment. Modern buildings usually have a high density of WiFi networks. Analyzing the SSID list, such as 'EastPointCity', 'WiFi.HK via EPCC', '3DG Jewellery', etc., it is reasonable to speculate that the user might be inside a shopping mall or a commercial area, possibly in Hong Kong, considering SSIDs like 'WiFi.HK via EPCC' and '3HK Pro3 5G'. 'EastPointCity' could be the name of a specific location or a mall.

Summary:

The user is likely walking inside a commercial building or a shopping mall, possibly located in Hong Kong or a region where there is a presence of Hong Kong-based telecom and WiFi services. The active and diverse WiFi networks and the absence of satellite signals confirm the indoor setting, and the high step count confirms the walking motion.



Lab, Los Angeles

Query Sensor Data

- 1. Step count: 3.0/min.
- 2. Satellites detected: 0. Carrier-to-noise: 0.0dB.
- 3. Total WiFi APs scanned: 9. SSID list: ['NESL-5', 'eduroam', 'UCLA_WEB', 'UCLA_WIFI', 'AlphaExp5G', 'AlphaExp', 'GL-AR150-ak', 'nesl-AP', ...]

Summary: The user is stationary and is likely inside a building on the UCLA campus or in its vicinity.



Airport, Singapore

Query Sensor Data

- 1. Step count: 0.0/min.
- 2. Satellites detected: 0. Carrier-to-noise: 0.0dB.
- 3. Total WiFi APs scanned: 5. SSID list: ['Mada's Samsung', '#WiFi@Changi', '#WiFi@Changi', '#WiFi@Changi', 'Eff'].

Summary: The user is stationary, and they are likely inside or close to Changi Airport in Singapore.



Sports Field, Singapore

Query Sensor Data



- 1. Step count: 118.0/min.
- 2. Satellites detected: 6. Carrier-to-noise: 36.37dB.
- 3. Total WiFi APs scanned: 0. SSID list: [].

Summary: The user is likely walking in an outdoor environment.


<https://arxiv.org/pdf/2310.09605>

2.3 构建多模态模型思路


对比学习 Contrastive Learning



2.4 Agent 的手脚




2.4 Agent 的手脚



函数
Function



终端命令
Command-Line Instructions




其它AI
Agents

```
def get_weather(city: str) -> str:
    weather_db = {
        "北京": "晴, 26°C, 南风2级",
        "上海": "小雨, 22°C, 东风3级",
        "广州": "多云, 30°C, 无持续风向",
        "深圳": "阵雨, 29°C, 微风"
    }
    return weather_db[city]
```


```
[(base) credoli@lihuichuwudeMac-mini ~ % cat Workspa
ce/HBPU-AI/data/course_info.txt
课程编号: CS101 | 课程名称: 线性回归实验 | 上课教室
: 综合楼 402 | 授课老师: 张教授
课程编号: CS102 | 课程名称: 深度学习与文字接龙 | 上
课教室: 实验楼 301 | 授课老师: 李副教授
课程编号: CS103 | 课程名称: Transformer与注意力机制
| 上课教室: 信息楼 508 | 授课老师: 王讲师
课程编号: CS104 | 课程名称: 检索增强生成(RAG)实战 |
上课教室: 科技楼 204 | 授课老师: 赵教授
[课程编号: CS105 | 课程名称: 人工智能大模型工具调用 ]
| 上课教室: 实验楼 502 | 授课老师: 刘副教授]
```




2.4 Agent 的手脚




2.5 Agent 的伙伴



2.5 Agent 的伙伴




Agents-to-Agents (A2A)



2.5 Agent 的伙伴

A2A 和 MCP 是什么关系？

A2A 和 MCP 共存，应根据实际的应用合理的设计。



2.5 Agent 的伙伴

Agents 之间如何交流会更好？




Figure 2: Representative topologies.










Figure 3: Assign functionally bipartite agents on nodes and edges, respectively.

<https://arxiv.org/pdf/2406.07155>


2.5 Agent 的伙伴

Agents 之间交流越丰富，结果可能越好



<https://arxiv.org/pdf/2406.07155>

2.6 Agent 如何达到目标?



2.6 Agent 如何达到目标?


Task List

Task 1: 完成Socket通信。Check: ✓
Task 2: Server端功能框架。Check: ✓
Task 3: 完成数据库表设计。Check: ✓
Task 4: 设计Web UI。Check:
Task 5: 设计测试案例。Check:
.....


Plan-and-Excute

让Agent拆解复杂任务并执行


计划往往赶不上变化



2.6 Agent 如何达到目标?




2.6 Agent 如何规划？



路径太长怎么办？

2.6 Agent 如何规划?


有些事不是想试就试的
不能出错，所以不能试



Tree Search for Language Model Agents
<https://arxiv.org/abs/2407.01476>


可是 AI 没有真实的经验
如何进行判断？

世界模型
World Model




AI 可否自己扮演
World Model?

< Think >




Is Your LLM Secretly a World Model of the Internet? Model-Based Planning for Web Agents


Please navigate to the 'Data Storage' category and purchase the least expensive disk with 512GB of storage.



Stage I: Simulation




Stage II: Execution




<https://arxiv.org/abs/2411.06559>



2.6 Agent 如何规划？




2.7 Agent 应该记什么？



Pressure Testing GPT-4 128K via "Needle In A HayStack"

Asking GPT-4 To Do Fact Retrieval Across Context Lengths & Document Depth




Goal: Test GPT-4 Ability To Retrieve Information From Large Context Windows

A fact was placed within a document. GPT-4 (1106-preview) was then asked to retrieve it. The output was evaluated for accuracy.

This test was run at 15 different document depths (top > bottom) and 15 different context lengths (1K > 128K tokens).

2x tests were run for larger contexts for a larger sample size.



2.7 Agent 应该记什么？



2.7 Agent 的记忆管理方法

维度	RAG	GraphRAG	LLM Wiki
核心思想	检索相似文本块	检索实体关系和证据	检索整理后的知识页面
数据形态	Chunks	实体、关系、Chunks	WiKi页面、来源
主要技术	分块、嵌入、重排序	实体抽取、关系抽取、多跳查询、RAG	LLM总结、概念页生成、页面索引、学习沉淀
适合问题	“这段资料里怎么说？”	“A 和 B 有什么关系？”	“帮我系统理解某个主题”
优点	简单、快速、成本低	关系清晰、可解释、多跳推理强	结构化、学习友好、适合长期沉淀
缺点	全局结构弱、关系理解弱	构建复杂、维护成本高	构建成本高、需要治理
适合场景	FAQ、文档问答	金融、医疗、法律等复杂业务网络	学习助手、领域助手、企业知识沉淀

关于AI Agent关键能力的思考



Chapter 5

Agents & Skills & Context Engineering

什么是智能体

智能体的核心能力

上下文工程


智能体的Skills



3.1 Context Engineering vs Prompt Engineering

Prompt Engineering


- 输入格式
- 神奇咒语



- 神奇咒语越来越不神奇.....



解数学应用题	GPT 3.5	2023 年 6月 的旧版本	2024 年 2 月 最新的版本
	没有神奇咒语	72%	85%
	“Let’s think step by step”	88%	89%

3.1 Context Engineering vs Prompt Engineering



3.2 Context 里面包含什么？

- User prompt (including examples ...)
- System prompt (persona, behaviors, etc.)
- Dialogue history
- Memory
- Relevant information from other sources
- Tool use
- Reasoning




3.2 Context 里面包含什么？

- User prompt (including examples ...)
- System prompt (persona, behaviors, etc.)
- Dialogue history
- Memory
- Relevant information from other sources
- Tool use
- Reasoning

} Very long!!!

Context Engineering 的核心目标：**避免超长的上下文**


3.3 为什么需要Context Engineering?



Source of image: <https://www.meibel.ai/post/understanding-the-impact-of-increasing-llm-context-windows>

3.3 为什么需要Context Engineering?

Context 并非越长越好




<https://www.databricks.com/blog/long-context-rag-performance-llms>

3.3 为什么需要Context Engineering?


Lost in the Middle

<https://arxiv.org/abs/2307.03172>

当前的LLMs无法有效地处理
上下文，即过长的上下文存在
信息丢失地问题



3.4 Context Engineering 要做什么？



3.4 Context Engineering 要做什么？

Select


Compress

Multi-Agent

3.4 Context Engineering 要做什么？

Select


- RAG



3.4 Context Engineering 要做什么？

Select


- 挑选工具 (Tool RAG)



3.4 Context Engineering 要做什么？

Select


- 挑选记忆 (Memory RAG)



不断回忆 Agent 一生的经历 ... ☹️


3.4 Context Engineering 要做什么？

Compress



3.4 Context Engineering 要做什么？

Compress




<https://arxiv.org/abs/2308.15022>

3.4 Context Engineering 要做什么？


Compress

主要压缩琐碎的操作过程，保留语义



A 餐厅定位成功，9/19下午6:00，十人
(Context不需要定位的详细过程)

Multi-Agent





明明都是由同一个模型驱动

为什么Multi-Agent比Single-Agent强？

3.4 Context Engineering要做什么？

Multi-Agent



推测：由于只收到其他AI的摘要信息，Context较短，能长期保持稳定

